

Lista 3 - Introdução à Análise de Sobrevivência MAE0354

Marcos de Oliveira Salvador Junior - NUSP(15474845)

Exercício 05

Letra a)




Figure 1: Curvas de Kaplan-Meier

Interpretação

Conforme a variável em questão analisada equivale ao **Tempo até a Obstrução da Sonda**, podemos observar em Figure 1, ambos os tipos de sonda parecem diferir ligeiramente entre si, sobretudo a sobreposição dos intervalos de confiança sugere uma semelhança dos grupos a ser identificada posteriormente. A **sonda plástica** demonstra uma menor probabilidade de sobrevivência ao decorrer dos tempos, enquanto a **WST** parece expressar um melhor controle até a obstrução.

Letra b)

Considerando um semestre composto de 182 dias, podemos designar essa estimativa da função de sobrevivência através da função de sobrevivência estimada de Kaplan-Meier: $\hat{S}_{KM}(182)$, já determinada. Assim, as estimativas do erro padrão podem ser dadas pela fórmula de **GreenWood** (tratada como nativa do R).

$$\sigma(\hat{S}_{KM}(182)) = \sqrt{\widehat{Var}(\hat{S}_{KM}(182))} = \hat{S}_{KM}(182) \sqrt{\sum_{j: z_j \leq 182} \frac{d_j}{(r_j - d_j)r_j}}$$

em que:

- d_j : número de falhas que ocorrem exatamente no tempo z_j
- r_j : número de indivíduos em risco imediatamente antes do tempo z_j

Nativamente isso pode ser dado no R, e determinado em uma tabela:

Table 1: Estimativa da probabilidade de permanecer sem obstrução após 182 dias.

Sonda	Estimativa	Erro.padrão
Protpla	0.5455	0.1278
WST	0.5527	0.1277

Comentários

Vemos que as probabilidades de sobrevivência são demasiadamente semelhantes, ainda mais pelos erros padrões. Isso expressa que o comportamento pode ser próximo a partir de tal faixa de tempo.

As estimativas de média e mediana podem ser determinadas estritamente nos tempos de ocorrência do evento e dispostas em uma tabela do seguinte modo:

Table 2: Tempos médios restritos e medianos por tipo de sonda

	Média.Restrita..dias.	Mediana.KM..dias.
sonda=Protpla	254.1	190
sonda=WST	360.0	309

Comentários

Observa-se na tabela Table 2 que os tempos médios restritos como também os medianos diferem amplamente entre os tipos de sonda. Essa diferença sugere a ocorrência de tempos mais elevados no grupo WST, o que contribui para evidências no controle da obstrução.

Letra c)

Sabemos que a estimativa da **Função de Sobrevivência**, da **Média** e da **Mediana** da Exponencial são conhecidas e facilmente determinadas através das estimativas para o parâmetro θ da distribuição:

$$\begin{cases} S(t) = e^{-\theta \cdot t} \\ \text{Média} = E(T) = 1/\theta \\ \text{Mediana} = \frac{\log(2)}{\theta} \end{cases}$$

O modelo determinado no R, utiliza uma parametrização diferente, desse modo, devemos especificar os parâmetros de outra forma, a fim de chegar às estimativas (vide o código no apêndice). Os resultados serão então, ajustados e apresentados em tabela.

Table 3: Estimativas da Exponencial

Sonda	Média	Mediana	S_182
Protpla	259.42	179.81	0.50
WST	476.00	329.94	0.68


Comentários

É possível observar com clareza um **deslize** entre as estimativas determinadas anteriormente e do modelo exponencial. Para a **prótese plástica** vemos um acréscimo significativo das medidas centrais, assim como um ligeiro decréscimo em relação à função de sobrevivência.

Ademais, para **WST**, vemos um acréscimo abundante das medidas de tendência central e também da probabilidade de sobrevivência ajustada no modelo exponencial em relação às

estimativas determinadas anteriormente, explicitando uma **superestimação**, isto é, modelo exponencial tende a produzir estimativas mais elevadas do que aquelas obtidas pelo método de Kaplan-Meier.

Letra d)



Comentários

Conforme a adequação do gráfico e das medidas determinadas anteriormente através da exponencial, vemos que o ajuste das funções de sobrevivência para os tempos em cada grupo é **razoável**, apesar dos sobreajustes e inadequações, principalmente para **WST**.

Letra e)

Utilizando a função `survdif` da biblioteca **Survival** conseguimos aplicar o teste log-rank para comparar as curvas de sobrevivência das duas populações do seguinte modo:

$$\begin{cases} H_0 : S_{protpla}(t) = S_{WST}(t) \\ H_1 : S_{protpla}(t) \neq S_{WST}(t) \end{cases}$$

Call:

```
survdif(formula = Surv(tempo, censura) ~ sonda, data = sondas,
        rho = 0)
```

	N	Observed	Expected	(O-E) ² /E	(O-E) ² /V
sonda=Protpla	18	12	9.44	0.694	1.33
sonda=WST	20	10	12.56	0.522	1.33

Chisq= 1.3 on 1 degrees of freedom, p= 0.2

Comentários

Para $\alpha = 0.05$ nível de significância, não há evidências suficientes para rejeição da hipótese nula (**p-valor = 0.2**) de igualdade entre as curvas de sobrevivência dos dois grupos. Portanto, podemos verificar que nossos dados não apontam diferença significativa entre os tempos até a obstrução de cada tipo de sonda.

Letra f)

Para utilizarmos o teste de **Gehan-Wilcoxon** ou **Peto-Peto**, especificamos no R $\rho = 1$, na mesma função utilizada anteriormente.

Call:

```
survdif(formula = Surv(tempo, censura) ~ sonda, data = sondas,
        rho = 1)
```

	N	Observed	Expected	(O-E) ² /E	(O-E) ² /V
sonda=Protpla	18	8.23	6.17	0.692	1.65
sonda=WST	20	6.35	8.42	0.507	1.65

Chisq= 1.7 on 1 degrees of freedom, p= 0.2

Comentários

O teste de **Gehan-Wilcoxon** também não indicou diferenças estatisticamente significativas entre as curvas de sobrevivência das sondas, assim como no teste **Log-Rank**. Entretanto, como as probabilidades de sobrevivência no 1º Semestre ajustadas são bastante semelhantes, podemos inferir que eventuais diferenças entre as sondas podem estar concentradas nos **tempos**

iniciais de acompanhamento. Nesse contexto, o teste de Gehan-Wilcoxon (ou Peto-Peto), que atribui maior peso aos eventos ocorridos no início do estudo, seria mais adequado para a comparação das curvas.

Contudo, os resultados ainda devem ser interpretados com cautela, uma vez que o tamanho reduzido da amostra pode limitar o poder dos testes estatísticos, auxiliando a não detecção de diferenças que eventualmente possam existir entre os grupos.

Letra g)

Conforme o ajuste determinado no R através da função *survreg* com as covariáveis (vide o apêndice), podemos determinar as taxas relativas através das exponenciais dos coeficientes de regressão. Disposto em uma tabela, vemos que:

Table 4: Estimativas das taxas relativas

Variavel	Taxa.Relativa
sondaWST	0.3813
sexoM	1.9449
idade	0.9372

Comentários

A sonda **WST** apresentou menor taxa de obstrução em relação à Prótese Plástica (**TR=0,3813**), enquanto indivíduos do **sexo masculino** apresentaram maior taxa de obstrução (**TR=1,9449**) em relação ao feminino. Além disso, o aumento da idade está ligeiramente associado a uma redução da taxa de obstrução, com diminuição aproximada de 6,3% para cada ano adicional de idade.

Letra h)

O teste de razão entre verossimilhanças entre tais modelos é o equivalente à testar se o parâmetro $\rho = 1$, a partir de que o modelo exponencial pode ser determinado através da Weibull sob tais condições.

	Terms	Resid.	Df	-2*LL	Test	Df	Deviance	Pr(>Chi)
1	sonda + sexo + idade		34	293.3729		NA	NA	NA
2	sonda + sexo + idade		33	292.8648	=	1	0.5080647	0.4759778

Conforme o valor-p (**0.47**) é superior ao nível de significância de 5%, não há evidências para rejeitar a hipótese nula. Portanto, conclui-se que o modelo Weibull não apresenta melhoria significativa de ajuste em relação ao modelo exponencial, sendo o último razoavelmente suficiente para a modelagem dos dados.

Apêndice (códigos no R)

```
# Carregamento dos pacotes
library(survminer)
library(survival)
library(kableExtra)
library(dplyr)
library(knitr)
library(patchwork)

# Leitura dos Dados
sondas <- read.csv("sondas.csv", header = TRUE, sep = ",")
sondas$evento = sondas$censura

# Filtrando os dados necessários
Protpla = sondas[sondas$sonda == "Protpla",]
WST = sondas[sondas$sonda != "Protpla",]

# Protpla
fit_protpla <- survfit(Surv(tempo, evento) ~ 1, data = Protpla)

p1 = ggsurvplot(
  fit_protpla,
  data = Protpla,
  conf.int = TRUE,
  color = "tomato",
  title = "Kaplan-Meier (Prótese Plástica)",
  conf.int.style = "ribbon",
  conf.int.alpha = 0.15,
  ggtheme = theme_survminer()
)

# WST
fit_WST <- survfit(Surv(tempo, evento) ~ 1, data = WST)
```

```

p2 = ggsurvplot(
  fit_WST,
  data = WST,
  conf.int = TRUE,
  title = "Kaplan Meier (Prótese WST)",
  color = "lightsteelblue",
  conf.int.style = "ribbon",
  conf.int.alpha = 0.15,
  ggtheme = theme_survminer()
)
p1$plot + p2$plot

# Estimativa para Prótese Plástica
s_protpla <- summary(fit_protpla, times = 182)
# Estimativa para Prótese WST
s_WST <- summary(fit_WST, times = 182)
tab_surv <- data.frame(
  Sonda = c("Protpla", "WST"),
  `Estimativa` = c(s_protpla$surv, s_WST$surv),
  `Erro padrão` = c(s_protpla$std.err, s_WST$std.err)
)
kable(
  tab_surv,
  digits = 4,
  caption = "Estimativa da probabilidade de permanecer sem obstrução após 182 dias.",
  booktabs = TRUE,
  format = "latex") %>% kable_styling(latex_options = "HOLD_position")

ajuste_km <- survfit(Surv(tempo, evento) ~ sonda,
  data = sondas,
  conf.int = 0.95)
limite_media <- min(tapply(sondas$tempo, sondas$sonda, max))
resumo <- summary(
  ajuste_km,
  rmean = limite_media
)$table

tabela <- data.frame(
  `Média Restrita (dias)` = round(resumo[, "rmean"], 2),
  `Mediana KM (dias)` = round(resumo[, "median"], 2)
)

```

```

kable(
  tabela,booktabs = TRUE, digits = 1)

# Ajuste do Modelo em ambas as sondas
fit_p_exp = survreg(Surv(tempo, censura) ~1, data = Protpla,dist = "exponential")
fit_WST_exp = survreg(Surv(tempo, censura) ~1, data = WST,dist = "exponential")

# Reparametrização necessária
mu_p = coef(fit_p_exp)[1]
theta_p = exp(-mu_p)
mu_wst = coef(fit_WST_exp)[1]
theta_wst = exp(-mu_wst)

# Cálculo das Estimativas para Sonda Plástica
media_p = 1/theta_p
mediana_p = log(2)/theta_p
S182_p <- exp(-theta_p * 182)

# Cálculo das Estimativas para WST
media_wst = 1/theta_wst
mediana_wst = log(2)/theta_wst
S182_wst <- exp(-theta_wst * 182)

# Tabela Geral
tabela_exp = data.frame(
  "Sonda" = c("Protpla","WST"),
  "Média" = c(media_p,media_wst),
  "Mediana" = c(mediana_p, mediana_wst),
  "S_182" = c(S182_p,S182_wst)
)
kable(
  tabela_exp,
  digits = 2,
  caption = "Estimativas da Exponencial",
  align = "c",
  booktabs = TRUE,
  format = "latex"
) |> kable_styling(latex_options = "HOLD_position")

# Ajustando a Estimativa de Kaplan Meyer para cada tipo de Sonda
fit <- survfit(Surv(tempo, censura) ~ sonda, data = sondas)

```

```

plot(fit, col = c("tomato", "lightsteelblue"), mark.time = TRUE,
     xlab = "Tempo", ylab = "S(t)",
     main = "Kaplan-Meier vs. Modelo Exponencial")

# Curva exponencial Protpla utilizando as estimativas
curve(exp(-theta_p * x), add = TRUE, col = "tomato", lty = 2, lwd = 2, from = 0)

# Curva exponencial WST utilizando as estimativas
curve(exp(-theta_wst * x), add = TRUE, col = "lightsteelblue", lty = 2, lwd = 2, from = 0)

legend("topright",
      legend = c("Protpla (KM)", "WST (KM)", "Protpla (Exp)", "WST (Exp)"),
      col = c("tomato", "lightsteelblue", "tomato", "lightsteelblue"),
      lty = c(1, 1, 2, 2),
      lwd = 2)

survdif(Surv(tempo, censura) ~ sonda, data = sondas, rho = 0)

# Executando o teste de Gehan-Wilcoxon
teste_gw <- survdif(Surv(tempo, censura) ~ sonda, data = sondas, rho = 1)
print(teste_gw)

# Ajuste do modelo de regressão exponencial com as covariáveis
fit_mult <- survreg(Surv(tempo, censura) ~ sonda + sexo + idade,
                    data = sondas,
                    dist = "exponential")

coefs <- coef(fit_mult)[-1] # remove intercepto
taxa_relativa <- exp(-coefs)
tab_rr <- data.frame(
  Variavel = names(taxa_relativa),
  `Taxa Relativa` = as.numeric(taxa_relativa))

kable(
  tab_rr, digits = 4,
  caption = "Estimativas das taxas relativas", align = "c",
  booktabs = TRUE, format = "latex"
) |> kable_styling(latex_options = "HOLD_position")

```

```
# 1. Ajuste do modelo de regressão exponencial
fit_exp <- survreg(Surv(tempo, censura) ~ sonda + sexo + idade, data = sondas, dist = "expon

# 2. Ajuste do modelo de regressão Weibull
fit_weibull <- survreg(Surv(tempo, censura) ~ sonda + sexo + idade, data = sondas, dist = "w

# 3. Teste da Razão de Verossimilhanças (LRT) comparando os dois modelos aninhados
anova(fit_exp, fit_weibull)
```