

MAE0354 - Introdução à Análise de Sobrevivência

Modelos de regressão paramétricos (Parte IV)

Antonio Carlos Pedroso de Lima

IME-USP

Modelos de Regressão em Análise de Sobrevida

Aulas Passadas

Abordagens para inclusão de covariáveis

- ▶ Modelos de Localização-Escala

$$Y_i = \log T_i = \mu + \mathbf{X}_i^T \boldsymbol{\gamma} + \sigma \varepsilon_i, \quad \varepsilon_i \sim \text{Alguma distribuição padrão}$$

- ▶ Modelos de Vida Acelerada

$$T = \Psi(\mathbf{X})T^{(0)} \text{ ou } S(t | \mathbf{X}) = S_0(\Psi(\mathbf{X})t), \quad T^{(0)} \text{ e } S_0(\cdot): \text{referência}$$

- ▶ Modelos com Taxas de Falha Proporcionais

$$\alpha(t | \mathbf{X}) = \alpha_0(t) \exp\{\mathbf{X}^T \boldsymbol{\beta}\}, \quad \alpha_0(\cdot): \text{referência}$$

Modelos de Regressão Paramétricos

Escolha da distribuição para T

Modelo paramétrico $\rightarrow$ supõe família de distribuições para T_i

Qual modelo paramétrico é o mais adequado para modelar os dados obtidos?

Vários recursos podem ser utilizados, entre eles:

- ▶ Método descritivo (observado x esperado - Kaplan-Meier)
- ▶ Método baseado em resíduos (Cox-Snell)

Cuidado!

Em análise de sobrevivência deve-se ter cautela com os métodos diagnósticos. É importante sempre utilizar várias ferramentas antes de se tomar uma decisão

Modelos de Regressão Paramétricos

Escolha da distribuição para T

Comparação das curvas de sobrevivência estimadas:

Kaplan-Meier x Estimada pelo modelo sob consideração

A partir do modelo nulo:

- ▶ Estimação de $S(t)$ por Kaplan-Meier - “valores observados”
- ▶ Estimação de $S(t)$ pelo modelo paramétrico - “valores ajustados”
- ▶ Inspeção visual da sobreposição das duas curvas

Modelos de Regressão Paramétricos

Avaliação do modelo paramétrico: Dados de obstrução de sondas

Estudo para avaliar o tempo livre de obstrução de sondas plásticas e metálicas em pacientes com **câncer de fígado**

- ▶ 35 pacientes
- ▶ 17 recebem sondas plásticas e 18 recebem sondas metálicas, via aleatorização
- ▶ Evento de interesse: obstrução da sonda (*icterícia*)
- ▶ Origem do tempo de acompanhamento: Implante da sonda

Modelos de Regressão Paramétricos

Escolha da distribuição de T - Exemplo


Código no R - Modelo Exponencial

```
> regressExp0 <- survreg(Surv(Tempo,Delta) ~ 1,data= sondas,
+   dist =  c("weibull","exponential","gaussian","logistic",
+             "lognormal","loglogistic")[2])
#
#Grafico da sobrevivencia - Exponencial e Kaplan-Meier
#
> percentis <- 1:99/100
> ptempo <- predict(regressExp0, newdata = data.frame(1),
+   type = "quantile", p=percentis,se=TRUE)
> plot(survfit(Surv(Tempo,Delta)~1,data = sondas),
+   main="Modelo Nulo: Kaplan-Meier x Exponencial",las=1)
> lines(ptempo$fit,1-percentis,col=2)
> legend(450,1,lty=1,col=c(1,2),
+   legend=c("Kaplan-Meier","Exponencial"),
> bty = "n")
```

Modelo de Regressão Paramétrico

Avaliação do modelo paramétrico: Dados de obstrução de sondas

Modelo Nulo: Kaplan-Meier x Exponencial



Modelos de Regressão Paramétricos

Avaliação do modelo paramétrico: Dados de obstrução de sondas


Código no R - Modelo Weibull

```
> regressWei0 <- survreg(Surv(Tempo,Delta)~1,data= sondas,  
+   dist = c("weibull","exponential","gaussian","logistic",  
+           "lognormal","loglogistic")[1])  
#  
#Grafico da sobrevivencia - Weibull e Kaplan-Meier  
#  
> ptempo <- predict(regressWei0, newdata = data.frame(1),  
+   type = "quantile", p=percentis,se=TRUE)  
> plot(survfit(Surv(Tempo,Delta)~1,data = sondas),  
+   main="Modelo Nulo: Kaplan-Meier x Weibull",las=1)  
> lines(ptempo$fit,1-percentis,col=2)  
+ legend(450,1,lty=1,col=c(1,2),  
+ legend=c("Kaplan-Meier", "Weibull"),  
+ bty = "n")
```

Modelos de Regressão Paramétricos

Avaliação do modelo paramétrico: Dados de obstrução de sondas

Modelo Nulo: Kaplan-Meier x Weibull



Modelos de Regressão Paramétricos

Avaliação do modelo paramétrico: Dados de obstrução de sondas


Código no R - Modelo Log-Normal

```
> regressLogN0 <- survreg(Surv(Tempo,Delta)~1,data= sondas,  
+   dist =  c("weibull","exponential","gaussian","logistic",  
+             "lognormal","loglogistic")[5])  
#  
#Grafico da sobrevivencia - LogNormal e Kaplan-Meier  
#  
> ptempo <- predict(regressLogN0, newdata = data.frame(1),  
+   type = "quantile", p=percentis,se=TRUE)  
> plot(survfit(Surv(Tempo,Delta)~1,data = sondas),  
+   main="Modelo Nulo: Kaplan-Meier x Log-Normal",las=1)  
> lines(ptempo$fit,1-percentis,col=2)  
> legend(450,1,lty=1,col=c(1,2),  
+   legend=c("Kaplan-Meier", "Log-Normal"),  
+   bty = "n")
```

Modelos de Regressão Paramétricos

Avaliação do modelo paramétrico: Dados de obstrução de sondas

Modelo Nulo: Kaplan-Meier x Log-Normal



Modelo de Regressão Paramétrico

Avaliação do modelo paramétrico: Dados de obstrução de sondas


Código no R - Modelo Log-logístico

```
> regressLoglog0 <- survreg(Surv(Tempo,Delta)~1,data= sondas,
+   dist =  c("weibull","exponential","gaussian","logistic",
+             "lognormal","loglogistic")[6])
#
#Grafico da sobrevivencia - Loglogistica e Kaplan-Meier
#
> ptempo <- predict(regressLoglog0, newdata = data.frame(1),
+   type = "quantile", p=percentis,se=TRUE)
> plot(survfit(Surv(Tempo,Delta)~1,data = sondas),
+   main="Modelo Nulo: Kaplan-Meier x Log-Logística",las=1)
> lines(ptempo$fit,1-percentis,col=2)
> legend(450,1,lty=1,col=c(1,2),
+   legend=c("Kaplan-Meier","Log-Logística"),
+   bty = "n")
```

Modelos de Regressão Paramétricos

Avaliação do modelo paramétrico: Dados de obstrução de sondas


Modelo Nulo: Kaplan-Meier x Log-Logística



Modelos de Regressão Paramétricos

Avaliação do modelo paramétrico: Dados de obstrução de sondas

Comparação dos modelos paramétricos com Kaplan-Meier



Modelos de Regressão Paramétricos

Escolha da distribuição para T

Método baseado no resíduo de Cox-Snell (na presença de covariáveis)

Suponha T caracterizada por

- ▶ Função de Sobrevivência $S_{\theta}(t \mid \mathbf{X})$
- ▶ Função de taxa de falha acumulada $A_{\theta}(t \mid) = \int_0^t \alpha_{\theta}(s \mid \mathbf{X}) \, ds$

Sendo $\hat{\theta}$ um estimador para θ , define-se

Resíduo Cox-Snell

$$e_i = \hat{A}(t_i \mid \mathbf{X}_i) = -\log \hat{S}_{\theta}(t_i \mid \mathbf{X}_i), \quad i = 1, \dots, n$$

Modelos de Regressão Paramétricos

Escolha da distribuição para T

Resíduo Cox-Snell

$$e_i = \hat{A}(t_i | \mathbf{X}_i) = -\log \hat{S}_\theta(t_i | \mathbf{X}_i), \quad i = 1, \dots, n$$

Exemplo: $T \sim \exp(e^{X\beta})$

$$S(t | X_i) = e^{-e^{X_i\beta}t} \Rightarrow A(t | X_i) = e^{X_i\beta}t$$

Se $\hat{\beta}$ é o EMV de β , então

$$e_i = \hat{A}(t_i | X_i) = e^{X_i\hat{\beta}_i}t_i, \quad i = 1, \dots, n.$$

Modelos de Regressão Paramétricos

Escolha da distribuição para T

Método baseado no resíduo de Cox-Snell

Dois resultados teóricos:

1. Se $X \sim S(\cdot)$, então $S(X) \sim \text{Unif}(0, 1)$
2. Se $U \sim \text{Unif}(0, 1)$, então $-\log U \sim \exp(1)$

$e_1, \dots, e_n$ resíduos Cox-Snell de um modelo **especificado corretamente**,

$\Rightarrow$ devem se comportar como uma amostra censurada de uma **distribuição exponencial de média 1**

Característica da exponencial com média 1

Se $X \sim \exp(1)$, então $S(x) = e^{-x} \Rightarrow A(x) = -\log S(x) = x$

Gráfico de $A(t | \mathbf{X}) \times t$ deve ser uma reta de 45° passando pela origem

Modelos de Regressão Paramétricos

Escolha da distribuição para T

Método baseado no resíduo de Cox-Snell

Procedimento

1. Dada a amostra $\{Z_i, \delta_i, \mathbf{X}_i\}$, $i = 1, \dots, n$, ajustar o modelo escolhido e estimar os parâmetros em θ .
2. Obter o resíduo Cox-Snell através de $e_i = A_{\hat{\theta}}(z_i \mid \mathbf{X}_i)$, $i = 1, \dots, n$
3. Estimar a função de sobrevivência baseada em $\{(e_i, \delta_i), i = 1, \dots, n\}$ usando Kaplan-Meier $[\hat{S}_{KM}(e_i)]$
4. Construir o gráfico $-\log[\hat{S}_{KM}(e_i)] \times e_i$
 - ▶ Se o gráfico estiver próximo de uma reta com inclinação 45° e passando pela origem, o modelo é adequado

Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo Exponencial

$$T \sim \text{Exp}(\theta) \Rightarrow Y = \log T \sim \text{Valor Extremo}$$

Modelo de Localização-Escala

$$Y_i = \mu + \mathbf{X}_i^T \boldsymbol{\gamma} + \varepsilon_i$$

$$S_{\varepsilon_i}(x) = P(\varepsilon_i > x) = \exp\{-e^x\}$$

$$\begin{aligned} S_{T_i}(t_i) &= P(T_i > t_i) = P(Y_i > \log t_i) \\ &= P(Y_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma} > \log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma}) \\ &= P(\varepsilon_i > \log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma}) = \exp\left\{-e^{\log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma}}\right\} \end{aligned}$$

Resíduo Cox-Snell para o modelo exponencial

$$e_i = \hat{A}(t_i | \mathbf{X}_i) = -\log S_{T_i}(t_i) = e^{\log t_i - \hat{\mu} - \mathbf{X}_i^T \hat{\boldsymbol{\gamma}}}, \quad i = 1, \dots, n$$

Modelos de Regressão Paramétricos

Avaliação do modelo paramétrico: Dados de obstrução de sondas

Estudo para avaliar o tempo livre de obstrução de sondas plásticas e metálicas em pacientes com **câncer de fígado**

- ▶ 35 pacientes
- ▶ 17 recebem sondas plásticas e 18 recebem sondas metálicas, via aleatorização
- ▶ Evento de interesse: obstrução da sonda (*icterícia*)
- ▶ Origem do tempo de acompanhamento: Implante da sonda

Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo Exponencial

Código R

```
# Resíduo Cox-Snell para o modelo Exponencial
> Reg_exp<-survreg(Surv(Tempo,Delta)~TipoSonda + Sexo +
+ Idade + BilirubinaAntes,data= sondas, dist = "exp")
> summary(Reg_exp)
> mu <- Reg_exp$coef[1]
> sigma <- Reg_exp$scale
> gamma <- Reg_exp$coef[2:5]

## Residuo Cox-Snell ##
> cs<-exp(with(sondas,log(Tempo)-mu-
+ (cbind(TipoSonda,Sexo,Idade,BilirubinaAntes)%*%gamma)))
> s.cs <- survfit(Surv(cs, sondas$Delta) ~ 1)
> plot(s.cs, mark.time=FALSE, fun="cumhaz", xlim=c(0,2.5),
+ conf.int=FALSE, las=1,xlab="Resíduos Cox-Snell",
+ ylab="Função de taxa acumulada estimada",
+ main="Avaliação da Adequabilidade do Modelo Exponencial")
> abline(a=0, b=1,col=2)
```


Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo Exponencial

Saída

	Value	Std. Error	z	p
(Intercept)	-0.767	2.3275	-0.330	0.74177
TipoSondaWST	0.787	0.4727	1.664	0.09603
SexoM	-0.330	0.4481	-0.737	0.46100
Idade	0.084	0.0296	2.840	0.00451
BilirubinaAntes	-0.009	0.0212	-0.425	0.67064

Scale fixed at 1



Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo Weibull

$T \sim \text{Weibull}(\theta, \rho) \Rightarrow Y = \log T \sim \text{Valor Extremo}$

Modelo de Localização-Escala

$$Y_i = \mu + \mathbf{X}_i^T \boldsymbol{\gamma} + \sigma \varepsilon_i$$

$$S_{\varepsilon_i}(x) = P(\varepsilon_i > x) = \exp\{-e^x\}$$

$$\begin{aligned} S_{T_i}(t_i) &= P(T_i > t_i) = P(Y_i > \log t_i) \\ &= P[(Y_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma > (\log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma] \\ &= P[\varepsilon_i > (\log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma] = \exp\left\{-e^{(\log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma}\right\} \end{aligned}$$

Resíduo Cox-Snell para o modelo Weibull

$$e_i = \hat{A}(t_i | \mathbf{X}_i) = -\log S_{T_i}(t_i) = e^{(\log t_i - \hat{\mu} - \mathbf{X}_i^T \hat{\boldsymbol{\gamma}})/\hat{\sigma}}, \quad i = 1, \dots, n$$

Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo Weibull

Código R

```
# Resíduo Cox-Snell para o modelo Weibull
> Reg_Wei<-survreg(Surv(Tempo,Delta)~TipoSonda + Sexo +
+ Idade + BilirubinaAntes,data= sondas, dist = "wei")
> summary(Reg_Wei)
> mu <- Reg_Wei$coef[1]
> sigma <- Reg_Wei$scale

## Residuo CoxSnell ##
> cs<-exp(with(sondas, (log(Tempo)-mu-
+ (cbind(TipoSonda, Sexo, Idade,
+      BilirubinaAntes)%*%gamma))/sigma))
> s.cs <- survfit(Surv(cs, sondas$Delta) ~ 1)
> plot(s.cs, mark.time=FALSE, fun="cumhaz",
+      xlab="Resíduos Cox-Snell",
+      ylab="Função de taxa acumulada estimada",
+      xlim=c(0,2.5), las=1,
+      conf.int=FALSE,
+      main="Avaliação da Adequabilidade do Modelo Weibull")
> abline(a=0, b=1,col=2)
```


Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo Weibull

Saída

	Value	Std. Error	z	p
(Intercept)	-0.68850	2.2373	-0.308	0.75828
TipoSondaWST	0.74472	0.4690	1.588	0.11228
SexoM	-0.32610	0.4266	-0.764	0.44458
Idade	0.08324	0.0283	2.937	0.00332
BilirubinaAntes	-0.00946	0.0200	-0.472	0.63680
Log(scale)	-0.05137	0.1682	-0.305	0.76001

Scale= 0.95



Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo LogNormal

$$T \sim \text{LogNormal} \Rightarrow Y = \log T \sim \text{Normal}$$

Modelo de Localização-Escala

$$Y_i = \mu + \mathbf{X}_i^T \boldsymbol{\gamma} + \sigma \varepsilon_i$$

$$S_{\varepsilon_i}(x) = 1 - \Phi(x), \quad \Phi : \text{Distribuição acumulada da } \mathcal{N}(0, 1)$$

$$\begin{aligned} S_{T_i}(t_i) &= P(T_i > t_i) = P(Y_i > \log t_i) \\ &= P[(Y_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma > (\log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma] \\ &= P[\varepsilon_i > (\log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma] = 1 - \Phi[(\log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma] \end{aligned}$$

Resíduo Cox-Snell para o modelo LogNormal

$$\begin{aligned} e_i &= \hat{A}(t_i | \mathbf{X}_i) = -\log S_{T_i}(t_i) = -\log[1 - \Phi((\log t_i - \hat{\mu} - \mathbf{X}_i^T \hat{\boldsymbol{\gamma}})/\hat{\sigma})], \\ i &= 1, \dots, n \end{aligned}$$

Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo LogNormal

Código R

```
# Resíduo Cox-Snell para o modelo LogNormal
> Reg_LogN<-survreg(Surv(Tempo,Delta)~ TipoSonda + Sexo +
+ Idade + BilirubinaAntes, data= sondas, dist = "lognormal")
> summary(Reg_LogN)
> xgamma <- with(sondas,cbind(1,TipoSonda, Sexo, Idade,
+ BilirubinaAntes)%*%Reg_LogN$coefficients[1:5])
> sigma <- Reg_LogN$scale

## Residuo CoxSnell ##
> cs<- -log(pnorm((log(sondas$Tempo)- xgamma)/sigma,
+ lower.tail = FALSE))
> s.cs <- survfit(Surv(cs, sondas$Delta) ~ 1)
> plot(s.cs, mark.time=FALSE, fun="cumhaz",
+ xlab="Resíduos Cox-Snell",
+ ylab="Função de taxa acumulada estimada",
+ xlim=c(0,1.5),
+ conf.int=FALSE, las=1,
+ main="Avaliação da Adequabilidade do Modelo LogNormal")
> abline(a=0, b=1,col=2)
```


Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo LogNormal

Saída

	Value	Std. Error	z	p
(Intercept)	0.0224	2.7408	0.00818	0.9935
TipoSondaWST	1.3194	0.5982	2.20582	0.0274
SexoM	-0.0395	0.5513	-0.07157	0.9429
Idade	0.0616	0.0340	1.81316	0.0698
BilirubinaAntes	-0.0118	0.0303	-0.38891	0.6973
Log(scale)	0.3179	0.1503	2.11516	0.0344

Scale= 1.37



Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo Loglogística

$T \sim \text{Loglogística} \Rightarrow Y = \log T \sim \text{Logística}$

Modelo de Localização-Escala

$$Y_i = \mu + \mathbf{X}_i^T \boldsymbol{\gamma} + \sigma \varepsilon_i$$

$$S_{\varepsilon_i}(x) = 1/(1 + x), \quad -\infty < x < +\infty$$

$$\begin{aligned} S_{T_i}(t_i) &= P(T_i > t_i) = P(Y_i > \log t_i) \\ &= P[(Y_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma > (\log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma] \\ &= P[\varepsilon_i > (\log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma] = \frac{1}{1 + e^{(\log t_i - \mu - \mathbf{X}_i^T \boldsymbol{\gamma})/\sigma}} \end{aligned}$$

Resíduo Cox-Snell para o modelo Loglogístico

$$e_i = \hat{A}(t_i | \mathbf{X}_i) = -\log S_{T_i}(t_i) = \log[1 + e^{(\log t_i - \hat{\mu} - \mathbf{X}_i^T \hat{\boldsymbol{\gamma}})/\hat{\sigma}}], \quad i = 1, \dots, n$$

Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo Loglogística

Código R

```
# Resíduo Cox-Snell para o modelo loglogístico
> Reg_Llog<-survreg(Surv(Tempo,Delta)~TipoSonda+Sexo+Idade+
+      BilirubinaAntes,data=sondas,dist="loglogistic")
> summary(Reg_Llog)
> mu <- Reg_Llog$coef[1]
> sigma <- Reg_Llog$scale
> xgamma <- with(sondas,cbind(1,TipoSonda,Sexo,Idade,
+      BilirubinaAntes)%*% Reg_Llog$coefficients[1:5])

## Residuo CoxSnell ##
> cs <- log(1 + exp((log(sondas$Tempo)-xgamma)/sigma))
> s.cs <- survfit(Surv(cs, sondas$Delta) ~ 1)
> plot(s.cs, mark.time=FALSE, fun="cumhaz",
+ xlab="Resíduos Cox-Snell",
+ ylab="Função de taxa acumulada estimada", xlim=c(0,2.5),
+ conf.int=FALSE, las=1,
+ main="Avaliação da Adequabilidade do Modelo LogLogístico")
> abline(a=0, b=1,col=2)
```


Modelos de Regressão Paramétricos

Escolha da distribuição para T - Resíduo Cox-Snell - Exemplo Loglogística

Saída

	Value	Std. Error	z	p
(Intercept)	-0.8749	2.2437	-0.3900	0.6966
TipoSondaWST	1.1012	0.5045	2.1828	0.0291
SexoM	-0.1335	0.4626	-0.2885	0.7730
Idade	0.0748	0.0280	2.6692	0.0076
BilirubinaAntes	-0.0013	0.0298	-0.0435	0.9653
Log(scale)	-0.3405	0.1807	-1.8845	0.0595

Scale= 0.711



Modelos de Regressão Paramétricos

Exemplo de obstrução de sondas - Modelo Escolhido: Exponencial

	Value	Std. Error	z	p
(Intercept)	-0.767	2.3275	-0.330	0.74177
TipoSondaWST	0.787	0.4727	1.664	0.09603
SexoM	-0.330	0.4481	-0.737	0.46100
Idade	0.084	0.0296	2.840	0.00451
BilirubinaAntes	-0.009	0.0212	-0.425	0.67064

Scale fixed at 1

Exponential distribution

Loglik(model)= -147.6 Loglik(intercept only)= -153.4

Chisq= 11.64 on 4 degrees of freedom, p= 0.02

Number of Newton-Raphson Iterations: 5

n=34 (4 observations deleted due to missingness)

Sexo e BilirrubinaAntes não significantes

Modelos de Regressão Paramétricos

Exemplo de obstrução de sondas - Modelo Escolhido: Exponencial

	Value	Std. Error	z	p
(Intercept)	-1.4416	2.139	-0.674	0.50035
TipoSondaWST	0.8255	0.448	1.842	0.06548
Idade	0.0891	0.028	3.188	0.00143

Scale fixed at 1
Exponential distribution
Loglik(model)= -154.4 Loglik(intercept only)= -159.8
Chisq= 10.71 on 2 degrees of freedom, p= 0.0047

Reparametrizando: $\hat{\beta}_{\text{Tipo}} = -\hat{\gamma}_1 = -0.8255$

$$\frac{\alpha(t \mid \text{metálica})}{\alpha(t \mid \text{plástica})} = e^{\beta_{\text{Tipo}}} \Rightarrow e^{\hat{\beta}_{\text{Tipo}}} = e^{-0.8255} = 0.44 \quad \forall t \geq 0$$

Conclusão (taxas proporcionais)

Taxa de obstrução para pacientes com sonda metálica é aproximadamente 44% da taxa para pacientes de mesma idade utilizando sonda plástica

Modelos de Regressão Paramétricos

Taxa relativa - Intervalo de confiança

Taxas proporcionais

$$\alpha(t | \mathbf{X}) = \alpha_0(t) \exp\{\mathbf{X}^T \boldsymbol{\beta}\}$$

Vimos que $\mathbf{X}_k$ e $\mathbf{X}_\ell$: covariáveis para dois indivíduos com mesmas características exceto a j -ésima, que difere por uma unidade,

$$RR(\mathbf{X}_\ell | \mathbf{X}_k) = \frac{\alpha(t | \mathbf{X}_\ell)}{\alpha(t | \mathbf{X}_k)} = e^{\beta_\ell}$$

Obtendo o E.M.V. $\hat{\beta}$ para β , segue, pelo princípio da invariância, que o E.M.V. para RR é

$$\widehat{RR}(\mathbf{X}_\ell | \mathbf{X}_k) = e^{\hat{\beta}_\ell}$$

Modelos de Regressão Paramétricos

Taxa relativa - Intervalo de confiança

Como $\hat{\beta}_\ell$ é um E.M.V., segue que, sob H_0 ,

$$\frac{\hat{\beta}_\ell}{\hat{\sigma}_\ell} \xrightarrow{\mathcal{D}} \mathcal{N}(0, 1),$$

$\hat{\sigma}_\ell$ é obtido da inversa da *informação observada*. Logo,

$$IC(\beta_\ell, \gamma) = [\hat{\beta}_\ell - z_{(1-\alpha/2)} \hat{\sigma}_\ell ; \hat{\beta}_\ell + z_{(1-\alpha/2)} \hat{\sigma}_\ell]$$

Intervalo de confiança para a taxa relativa

$$IC[RR(\mathbf{X}_\ell \mid \mathbf{X}_k), 1 - \alpha] = [e^{\hat{\beta}_\ell - z_{(1-\alpha/2)} \hat{\sigma}_\ell} ; e^{\hat{\beta}_\ell + z_{(1-\alpha/2)} \hat{\sigma}_\ell}]$$

Modelos de Regressão Paramétricos

Taxa relativa - Intervalo de confiança - Exemplo

	Value	Std. Error	z	p
(Intercept)	-1.4416	2.139	-0.674	0.50035
TipoSondaWST	0.8255	0.448	1.842	0.06548
Idade	0.0891	0.028	3.188	0.00143

Scale fixed at 1
Exponential distribution
Loglik(model)= -154.4 Loglik(intercept only)= -159.8
Chisq= 10.71 on 2 degrees of freedom, p= 0.0047

$$\hat{\beta}_{\text{Tipo}} = -\hat{\gamma}_1 = -0.8255 \Rightarrow \hat{\sigma}_{\text{Tipo}}^2 = \text{Var}(\hat{\beta}_{\text{Tipo}}) = \text{Var}(-\hat{\gamma}_1) = (0.448)^2$$

Segue que, para $1 - \alpha = 95\%$,

$$\begin{aligned} IC[RR(\mathbf{X}_\ell \mid \mathbf{X}_k), 1 - \alpha] &= [e^{\hat{\beta}_{\text{Tipo}} - z_{(1-\frac{\alpha}{2})} \hat{\sigma}_{\text{Tipo}}} ; e^{\hat{\beta}_{\text{Tipo}} + z_{(1-\frac{\alpha}{2})} \hat{\sigma}_{\text{Tipo}}}] \\ &= e^{-0.826 - 1.96 \times 0.448} ; e^{-0.826 + 1.96 \times 0.448} \\ &= [0.182 ; 1.054] \end{aligned}$$