


A Aprendizagem é viável?

Morgan André

MAE0501 - Aprendizagem Estatística




2º Semestre 2026

Lembrete






Generalização, Sobreajuste e a Navalha de Ockham


Generalização e Sobreajuste



$$f = -1$$



$$f = +1$$



$$f = ?$$

Generalização e Sobreajuste

Considere o caso extremo em que o conjunto de hipóteses $\mathcal{H}$ não inclui nenhum tipo de restrição, i.e.:

$$\mathcal{H} = \{\text{todas as funções } h : \mathcal{X} \rightarrow \mathcal{Y}\}.$$

Generalização e Sobreajuste

Considere o caso extremo em que o conjunto de hipóteses $\mathcal{H}$ não inclui nenhum tipo de restrição, i.e.:

$$\mathcal{H} = \{\text{todas as funções } h : \mathcal{X} \rightarrow \mathcal{Y}\}.$$

Afinal o único critério que temos para decidir da qualidade de uma determinada hipótese é o *desempenho* dessa hipótese nos dados de treinamento

Generalização e Sobreajuste

Considere o caso extremo em que o conjunto de hipóteses $\mathcal{H}$ não inclui nenhum tipo de restrição, i.e.:

$$\mathcal{H} = \{\text{todas as funções } h : \mathcal{X} \rightarrow \mathcal{Y}\}.$$

Afinal o único critério que temos para decidir da qualidade de uma determinada hipótese é o *desempenho* dessa hipótese nos dados de treinamento. Sendo assim fornecemos uma solução resolvendo qualquer tipo de problema de aprendizagem supervisionado. Defina g da forma seguinte:

$$g(\mathbf{x}) = \begin{cases} y_k & \text{se } \mathbf{x} = \mathbf{x}_k, \\ y \text{ qualquer} & \text{caso contrario.} \end{cases}$$

Generalização e Sobreajuste

Considere o caso extremo em que o conjunto de hipóteses $\mathcal{H}$ não inclui nenhum tipo de restrição, i.e.:

$$\mathcal{H} = \{\text{todas as funções } h : \mathcal{X} \rightarrow \mathcal{Y}\}.$$

Afinal o único critério que temos para decidir da qualidade de uma determinada hipótese é o *desempenho* dessa hipótese nos dados de treinamento. Sendo assim fornecemos uma solução resolvendo qualquer tipo de problema de aprendizagem supervisionado. Defina g da forma seguinte:

$$g(\mathbf{x}) = \begin{cases} y_k & \text{se } \mathbf{x} = \mathbf{x}_k, \\ y \text{ qualquer} & \text{caso contrario.} \end{cases}$$



Generalização e Sobreajuste

Considere o caso extremo em que o conjunto de hipóteses $\mathcal{H}$ não inclui nenhum tipo de restrição, i.e.:

$$\mathcal{H} = \{\text{todas as funções } h : \mathcal{X} \rightarrow \mathcal{Y}\}.$$

Afinal o único critério que temos para decidir da qualidade de uma determinada hipótese é o *desempenho* dessa hipótese nos dados de treinamento. Sendo assim fornecemos uma solução resolvendo qualquer tipo de problema de aprendizagem supervisionado. Defina g da forma seguinte:

$$g(\mathbf{x}) = \begin{cases} y_k & \text{se } \mathbf{x} = \mathbf{x}_k, \\ y \text{ qualquer} & \text{caso contrario.} \end{cases}$$



Generalização e Sobreajuste

Considere o caso extremo em que o conjunto de hipóteses $\mathcal{H}$ não inclui nenhum tipo de restrição, i.e.:

$$\mathcal{H} = \{\text{todas as funções } h : \mathcal{X} \rightarrow \mathcal{Y}\}.$$

Afinal o único critério que temos para decidir da qualidade de uma determinada hipótese é o *desempenho* dessa hipótese nos dados de treinamento. Sendo assim fornecemos uma solução resolvendo qualquer tipo de problema de aprendizagem supervisionado. Defina g da forma seguinte:

$$g(\mathbf{x}) = \begin{cases} y_k & \text{se } \mathbf{x} = \mathbf{x}_k, \\ y \text{ qualquer} & \text{caso contrario.} \end{cases}$$



Generalização e Sobreajuste

Considere o caso extremo em que o conjunto de hipóteses $\mathcal{H}$ não inclui nenhum tipo de restrição, i.e.:

$$\mathcal{H} = \{\text{todas as funções } h : \mathcal{X} \rightarrow \mathcal{Y}\}.$$

Afinal o único critério que temos para decidir da qualidade de uma determinada hipótese é o *desempenho* dessa hipótese nos dados de treinamento. Sendo assim fornecemos uma solução resolvendo qualquer tipo de problema de aprendizagem supervisionado. Defina g da forma seguinte:

$$g(\mathbf{x}) = \begin{cases} y_k & \text{se } \mathbf{x} = \mathbf{x}_k, \\ y \text{ qualquer} & \text{caso contrario.} \end{cases}$$



Generalização e Sobreajuste

Considere o caso extremo em que o conjunto de hipóteses $\mathcal{H}$ não inclui nenhum tipo de restrição, i.e.:

$$\mathcal{H} = \{\text{todas as funções } h : \mathcal{X} \rightarrow \mathcal{Y}\}.$$

Afinal o único critério que temos para decidir da qualidade de uma determinada hipótese é o *desempenho* dessa hipótese nos dados de treinamento. Sendo assim fornecemos uma solução resolvendo qualquer tipo de problema de aprendizagem supervisionado. Defina g da forma seguinte:

$$g(\mathbf{x}) = \begin{cases} y_k & \text{se } \mathbf{x} = \mathbf{x}_k, \\ c & \text{caso contrario.} \end{cases}$$



Generalização e Sobreajuste

Obviamente a solução proposta não tem a menor chance de apresentar um bom desempenho fora dos dados de treinamento

Generalização e Sobreajuste

Obviamente a solução proposta não tem a menor chance de apresentar um bom desempenho fora dos dados de treinamento. Isto é: a solução apresenta um poder de **generalização** nulo, *não é aprendizagem, é memorização*.

Generalização e Sobreajuste

Obviamente a solução proposta não tem a menor chance de apresentar um bom desempenho fora dos dados de treinamento. Isto é: a solução apresenta um poder de **generalização** nulo, *não é aprendizagem, é memorização*.

Preocupados demais com o desempenho da nossa função nos dados de treinamento, esquecemos que havia um padrão para aprender

Generalização e Sobreajuste

Obviamente a solução proposta não tem a menor chance de apresentar um bom desempenho fora dos dados de treinamento. Isto é: a solução apresenta um poder de **generalização** nulo, *não é aprendizagem, é memorização*.

Preocupados demais com o desempenho da nossa função nos dados de treinamento, esquecemos que havia um padrão para aprender. Esse fenômeno é chamado de **sobreajuste** (*overfitting*).

Navalha de Ockham

A chamada *Navalha de Ockham* é um princípio geral, nomeado em homenagem ao filósofo medieval Guilherme de Ockham, essencial em todos os ramos da ciência. Este princípio foi reformulado pelo T. Mitchell no âmbito da aprendizagem estatística em 1997: "always choose the shortest explanation for the observed data".



Navalha de Ockham

A chamada *Navalha de Ockham* é um princípio geral, nomeado em homenagem ao filósofo medieval Guilherme de Ockham, essencial em todos os ramos da ciência. Este princípio foi reformulado pelo T. Mitchell no âmbito da aprendizagem estatística em 1997: "always choose the shortest explanation for the observed data".



De maneira mais formal, o nosso problema é a ausência de restrições no conjunto das hipóteses $\mathcal{H}$

Navalha de Ockham

A chamada *Navalha de Ockham* é um princípio geral, nomeado em homenagem ao filósofo medieval Guilherme de Ockham, essencial em todos os ramos da ciência. Este princípio foi reformulado pelo T. Mitchell no âmbito da aprendizagem estatística em 1997: "always choose the shortest explanation for the observed data".




De maneira mais formal, o nosso problema é a ausência de restrições no conjunto das hipóteses $\mathcal{H}$. No entanto, isto é apenas uma parte da resposta: enquanto a presença de restrições no conjunto $\mathcal{H}$ é uma condição necessária para a generalização, ela não fornece sozinha uma justificativa teórica da viabilidade da aprendizagem.


Generalização e Sobreajuste




Generalização e Sobreajuste




Generalização e Sobreajuste




Generalização e Sobreajuste




Generalização e Sobreajuste




Generalização e Sobreajuste



Generalização e Sobreajuste




Generalização e Sobreajuste




A Lei dos Grandes Números & a Desigualdade de Hoeffding


Cadê a probabilidade?



Cadê a probabilidade?



Cadê a probabilidade?



Erros Intra-amostrai e Extra-amostrai

O domínio $\mathcal{X}$ da função objetiva f deve ser interpretado como um **espaço amostral**

Erros Intra-amostal e Extra-amostal

O domínio $\mathcal{X}$ da função objetiva f deve ser interpretado como um **espaço amostral**, associado a alguma probabilidade $\mathbb{P}$ (possivelmente desconhecida)

Erros Intra-amostal e Extra-amostal

O domínio $\mathcal{X}$ da função objetiva f deve ser interpretado como um **espaço amostral**, associado a alguma probabilidade $\mathbb{P}$ (possivelmente desconhecida). A amostra de treinamento foi sorteada a partir dessa probabilidade $\mathbb{P}$, de forma independente

Erros Intra-amostal e Extra-amostal

O domínio $\mathcal{X}$ da função objetiva f deve ser interpretado como um **espaço amostral**, associado a alguma probabilidade $\mathbb{P}$ (possivelmente desconhecida). A amostra de treinamento foi sorteada a partir dessa probabilidade $\mathbb{P}$, de forma independente.

Aquele cenário nos permite definir duas quantidades crucial na teoria da aprendizagem: Os erros **intra-amostal** e **extra-amostal** associados à uma determinada hipótese $h \in \mathcal{H}$.

$$E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n \mathbb{1}\{h(\mathbf{x}_k) \neq f(\mathbf{x}_k)\} \quad E_{\text{out}}(h) = \mathbb{P}[h(\mathbf{x}) \neq f(\mathbf{x})]$$

Erros Intra-amostal e Extra-amostal

$$E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n \mathbb{1}\{h(\mathbf{x}_k) \neq f(\mathbf{x}_k)\} \quad E_{\text{out}}(h) = \mathbb{P}[h(\mathbf{x}) \neq f(\mathbf{x})]$$

Erros Intra-amostal e Extra-amostal

$$E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n \mathbb{1}\{h(\mathbf{x}_k) \neq f(\mathbf{x}_k)\} \quad E_{\text{out}}(h) = \mathbb{P}[h(\mathbf{x}) \neq f(\mathbf{x})]$$

A aproximação $g \approx f$ pode agora ser interpretada como

$$E_{\text{out}}(g) \approx 0.$$

Erros Intra-amostal e Extra-amostal

$$E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n \mathbb{1}\{h(\mathbf{x}_k) \neq f(\mathbf{x}_k)\} \quad E_{\text{out}}(h) = \mathbb{P}[h(\mathbf{x}) \neq f(\mathbf{x})]$$

A aproximação $g \approx f$ pode agora ser interpretada como

$$E_{\text{out}}(g) \approx 0.$$

A **generalização** pode agora ser definida de forma mais precisa:

$$E_{\text{in}}(g) \approx E_{\text{out}}(g).$$

Erros Intra-amostal e Extra-amostal

$$E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n \mathbb{1}\{h(\mathbf{x}_k) \neq f(\mathbf{x}_k)\} \quad E_{\text{out}}(h) = \mathbb{P}[h(\mathbf{x}) \neq f(\mathbf{x})]$$

A aproximação $g \approx f$ pode agora ser interpretada como


$$E_{\text{out}}(g) \approx 0.$$

A **generalização** pode agora ser definida de forma mais precisa:


$$E_{\text{in}}(g) \approx E_{\text{out}}(g).$$

De fato, a exigência de **generalização** nos garante que, se conseguimos g tal que $E_{\text{in}}(g) \approx 0$, então teremos também $E_{\text{out}}(g) \approx 0$.


Erros Intra-amostal e Extra-amostal




Erros Intra-amostal e Extra-amostal




Erros Intra-amostal e Extra-amostal



Erros Intra-amostal e Extra-amostal



Erros Intra-amostrais e Extra-amostrais



A Lei dos Grandes Números

Teorema

Seja $(Z_k)_{k \geq 1}$ uma sequência de variáveis aleatórias *i.i.d.* com valor esperado μ , e seja $\bar{Z}_n = \frac{1}{n} \sum_{k=1}^n Z_k$ a média amostral. Então, para qualquer $\epsilon > 0$, temos:

$$\mathbb{P}(|\bar{Z}_n - \mu| > \epsilon) \xrightarrow{n \rightarrow \infty} 0$$

A Lei dos Grandes Números

Teorema

Seja $(Z_k)_{k \geq 1}$ uma sequência de variáveis aleatórias *i.i.d.* com valor esperado μ , e seja $\bar{Z}_n = \frac{1}{n} \sum_{k=1}^n Z_k$ a média amostral. Então, para qualquer $\epsilon > 0$, temos:

$$\mathbb{P}(|\bar{Z}_n - \mu| > \epsilon) \xrightarrow{n \rightarrow \infty} 0$$

No nosso caso, denotando $Z_k = \mathbb{1}\{h(\mathbf{x}_k) \neq f(\mathbf{x}_k)\}$, temos de fato uma sequência de variáveis aleatórias *i.i.d.* com:

$$\mu = \mathbb{P}(h(\mathbf{x}) \neq f(\mathbf{x})) = E_{\text{out}}(h) \qquad \bar{Z}_n = \frac{1}{n} \sum_{k=1}^n Z_k = E_{\text{in}}(h)$$

A Desigualdade de Hoeffding

Teorema

Seja $(Z_k)_{k \geq 0}$ uma sequência de variáveis aleatórias *i.i.d.* com valor esperado μ , e com valores num intervalo limitado $[a, b] \subset \mathbb{R}$:

$$\mathbb{P}(a \leq Z_k \leq b) = 1 \text{ para todo } k \geq 1.$$

Então para qualquer $\epsilon > 0$ e para todo $n \geq 1$ temos:

$$\mathbb{P}(|\bar{Z}_n - \mu| > \epsilon) \leq 2 \exp\left(-2 \frac{\epsilon^2 n}{(b - a)^2}\right)$$

A Desigualdade de Hoeffding

Teorema

Seja $(Z_k)_{k \geq 0}$ uma sequência de variáveis aleatórias *i.i.d.* com valor esperado μ , e com valores num intervalo limitado $[a, b] \subset \mathbb{R}$:

$$\mathbb{P}(a \leq Z_k \leq b) = 1 \text{ para todo } k \geq 1.$$

Então para qualquer $\epsilon > 0$ e para todo $n \geq 1$ temos:

$$\mathbb{P}(|\bar{Z}_n - \mu| > \epsilon) \leq 2 \exp\left(-2 \frac{\epsilon^2 n}{(b - a)^2}\right)$$

No nosso caso os Z_k tem valores no intervalo $[0, 1]$. Portanto:

$$\mathbb{P}(|E_{\text{in}}(h) - E_{\text{out}}(h)| > \epsilon) \leq 2e^{-2\epsilon^2 n}$$

A Desigualdade de Hoeffding

As desigualdades que fornecem uma quota sobre a probabilidade de uma determinada variável aleatória desviar de um determinado valor (tipicamente a média) são chamadas de **desigualdades de concentração**

A Desigualdade de Hoeffding

As desigualdades que fornecem uma quota sobre a probabilidade de uma determinada variável aleatória desviar de um determinado valor (tipicamente a média) são chamadas de **desigualdades de concentração**. Elas são em particular útil para determinar a velocidade da convergência na LGN.

A Desigualdade de Hoeffding

As desigualdades que fornecem uma quota sobre a probabilidade de uma determinada variável aleatória desviar de um determinado valor (tipicamente a média) são chamadas de **desigualdades de concentração**. Elas são em particular útil para determinar a velocidade da convergência na LGN.

A desigualdade de Hoeffding é uma delas. Certamente não é a mais fina, mas ela tem uma grande vantagem para o nosso problema: a quota não depende da média μ (i.e. do erro extra-amostrai E_{out}). Isto é crucial no nosso caso, pois o *erro extra-amostrai* é sempre desconhecido.

Demonstração da desigualdade

Proposição

Se Y é uma variável aleatória não negativa então para todo $c > 0$ temos:

$$\mathbb{P}(X \geq c) \leq \frac{\mathbb{E}(X)}{c}$$

Lema

Seja Y uma variável aleatória centrada ($\mathbb{E}(Y) = 0$) e com $\mathbb{P}(c \leq Y \leq d) = 1$ para algum intervalo $[c, d] \subset \mathbb{R}$. Então para todo $s > 0$ temos:

$$\mathbb{E} \left[e^{sY} \right] \leq \exp \left(\frac{s^2(d-c)^2}{8} \right)$$

A aprendizagem é viável?

Então, temos resolvido o problema da viabilidade da aprendizagem?

A aprendizagem é viável?

Então, temos resolvido o problema da viabilidade da aprendizagem?

→ Ainda não, pois temos considerado um problema de **verificação**, e não de aprendizagem

A aprendizagem é viável?

Então, temos resolvido o problema da viabilidade da aprendizagem?

→ Ainda não, pois temos considerado um problema de **verificação**, e não de aprendizagem.

Os problemas da viabilidade da aprendizagem e da generalização são centrais na teoria, e a desigualdade de Hoeffding não permite resolver a questão no maior grau de generalidade

A aprendizagem é viável?

Então, temos resolvido o problema da viabilidade da aprendizagem?

→ Ainda não, pois temos considerado um problema de **verificação**, e não de aprendizagem.

Os problemas da viabilidade da aprendizagem e da generalização são centrais na teoria, e a desigualdade de Hoeffding não permite resolver a questão no maior grau de generalidade. No entanto ela permite resolvê-la no caso particular $|\mathcal{H}| = m < \infty$.

A aprendizagem é viável?

Então, temos resolvido o problema da viabilidade da aprendizagem?

→ Ainda não, pois temos considerado um problema de **verificação**, e não de aprendizagem.

Os problemas da viabilidade da aprendizagem e da generalização são centrais na teoria, e a desigualdade de Hoeffding não permite resolver a questão no maior grau de generalidade. No entanto ela permite resolvê-la no caso particular $|\mathcal{H}| = m < \infty$.

Neste caso:

$$\mathbb{P}(|E_{\text{in}}(g) - E_{\text{out}}(g)| > \epsilon) \leq m 2e^{-2\epsilon^2 n}$$