

Lista 1

Exercício 1 - Perceptron

Consideramos o **perceptron** bidimensional. As hipóteses são da forma:

$$h(\mathbf{x}) = \text{sign} \left(\mathbf{w}^\top \begin{bmatrix} 1 \\ x \\ y \end{bmatrix} \right),$$


com $\mathbf{w} = (w_0, w_1, w_2) \in \mathbb{R}^3$ e $\mathbf{x} = (x, y) \in \mathbb{R}^2$. Suponha que temos os três seguintes pontos $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3 \in \mathbb{R}^2$, junto com os respectivos rótulos $y_1, y_2, y_3 \in \{-1, +1\}$: $\mathbf{x}_1 = (-1, -1)$ e $y_1 = +1$; $\mathbf{x}_2 = (2, 3)$ e $y_2 = +1$; $\mathbf{x}_3 = (2, -2)$ e $y_3 = -1$.

1. Seja $\mathbf{w}_0 = (0, 0, 1)$ e seja h_0 a hipótese associada ao vetor $\mathbf{w}_0$. Explícite a equação da reta em $\mathbb{R}^2$ separando as regiões:

$$\mathcal{X}^+ = \{(x, y) \in \mathbb{R}^2 : h_0(x, y) = +1\},$$

$$\mathcal{X}^- = \{(x, y) \in \mathbb{R}^2 : h_0(x, y) = -1\}.$$

2. Forneça o vetor $\mathbf{w} \in \mathbb{R}^3$ produzido pelo algoritmo do **perceptron** (PLA) com base nesses três pontos e com vetor inicial $\mathbf{w}_0$. Detalhe cada etapa e desenhe nos planos abaixo as retas associadas aos vetores intermediários $\mathbf{w}_0, \mathbf{w}_1, \dots$ obtidos em cada iteração.



Exercício 2 - Os Tipos de Aprendizagem

Para cada problema, selecione todas as categorias aplicáveis entre: regressão, classificação, supervisionado, não-supervisionado, aprendizado por reforço.

1. Prever o preço de uma casa com base em seu tamanho, localização e número de quartos.
2. Agrupar clientes em segmentos com base em seu comportamento de compra, sem rótulos prévios.
3. Ensinar um robô a navegar por um labirinto, recebendo recompensas por chegar à saída e penalidades por bater nas paredes.
4. Detectar se um e-mail é spam ou não com base em seu conteúdo e metadados.
5. Estimar o número de bicicletas alugadas em uma cidade a cada dia, usando dados históricos de clima e feriados.
6. Identificar diferentes espécies de flores com base numa foto.
7. Recomendar filmes para usuários com base em seu histórico de visualização e avaliações.
8. Recomendar filmes para usuários com base em seu histórico de visualização, sem avaliações.
9. Treinar um modelo para jogar um videogame, maximizando a pontuação por tentativa e erro.
10. Prever a temperatura para os próximos 7 dias usando dados históricos de clima.

Exercício 3 - Formula da Regressão Linear Simples

Nesse exercício obtemos as formulas apresentadas na Aula 1 para os coeficientes da regressão linear simples. Temos um conjunto de dados $(x_1, y_1), \dots, (x_n, y_n)$ com $x_k, y_k \in \mathbb{R}$. Realizar uma regressão linear consiste em achar os valores de α e β que minimizam a soma dos resíduos quadrados:

$$S(\alpha, \beta) = \sum_{k=1}^n (y_k - \alpha - \beta x_k)^2.$$

Observe que, uma vez a regressão realizada, os x_k são as variáveis, enquanto os α e β são coeficientes fixos. Ao contrario, na fase de ajustamento da regressão aos dados, os x_k e y_k são fixos, enquanto os α e β são as variáveis. Trata-se de minimizar a função polinomial bivariada S .

1. Mostrar que o ponto critico $(\hat{\alpha}, \hat{\beta})$ da função S é dado por:

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x} \qquad \hat{\beta} = \frac{\sum_{k=1}^n x_k y_k - \bar{y} \sum_{k=1}^n x_k}{\sum_{k=1}^n x_k^2 - \bar{x} \sum_{k=1}^n x_k}$$

com as notações $\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$ e $\bar{y} = \frac{1}{n} \sum_{k=1}^n y_k$.

Lembrete: um ponto critico é um ponto em que o vetor gradiente é nulo:

$$\nabla S = \begin{bmatrix} \frac{\partial S}{\partial \alpha} \\ \frac{\partial S}{\partial \beta} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

2. Mostrar que:

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

3. Mostrar que o determinante da matriz Hessiana $H(S)$ vale:

$$\det H(S) = n \sum_{k=1}^n (x_k - \bar{x})^2$$

Lembrete: A matriz Hessiana da função S é definida como:

$$H(S) = \begin{bmatrix} \frac{\partial^2 S}{\partial \alpha^2} & \frac{\partial^2 S}{\partial \alpha \partial \beta} \\ \frac{\partial^2 S}{\partial \beta \partial \alpha} & \frac{\partial^2 S}{\partial \beta^2} \end{bmatrix}$$

4. Concluir que $(\hat{\alpha}, \hat{\beta}) = \arg \min S(\alpha, \beta)$.

Exercício 4 - Convergência do Perceptron

Nesse exercício demonstramos que o algoritmo do perceptron (PLA) sempre converge quando os dados são linearmente separáveis. Seja $\mathbf{w}^*$ um vetor de pesos ideal, separando perfeitamente os dados. O conjunto de dados de treinamento é $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$, onde os $\mathbf{x}_1, \dots, \mathbf{x}_n$ são vetores de $\mathbb{R}^d$, e os $y_1, \dots, y_n$ são rótulos em $\{-1, +1\}$. Lembramos que, em cada iteração $t \in \mathbb{N}$, o PLA escolhe um ponto incorretamente classificado $(\mathbf{x}(t), y(t)) \in \mathcal{D}$ e aplica a seguinte regra de atualização:

$$\mathbf{w}(t+1) = \mathbf{w}(t) + y(t)\mathbf{x}(t).$$

Denotamos $t_{\max}$ a última iteração, com $t_{\max} = \infty$ se o PLA não converge, e para simplificar assumimos que o algoritmo é inicializado com o vetor nulo $\mathbf{w}(0) = \mathbf{0}$.

- Justificar que $\rho = \min_{1 \leq k \leq n} y_k \mathbf{w}^{*\top} \mathbf{x}_k > 0$.
- Seja $t \in \mathbb{N} \cap [0, t_{\max}]$ uma iteração qualquer antes da convergência. Mostrar que $\mathbf{w}^\top(t) \mathbf{w}^* \geq t\rho$.
- Justificar que $y(t-1) \mathbf{w}^\top(t-1) \mathbf{x}(t-1) \leq 0$ e deduzir que $\|\mathbf{w}(t)\|^2 \leq \|\mathbf{w}(t-1)\|^2 + \|\mathbf{x}(t-1)\|^2$.

Notação: Para um vetor $\mathbf{z} \in \mathbb{R}^d$ qualquer $\|\mathbf{z}\| = \sqrt{\sum_{i=1}^d z_i^2}$ denota a norma euclidiana.

- Denotando $R = \max_{1 \leq k \leq n} \|\mathbf{x}_k\|$, mostrar por indução (usando o item precedente) que $\|\mathbf{w}(t)\|^2 \leq tR^2$.
- Usando os itens 2 e 4 mostrar que:

$$\frac{\mathbf{w}^\top(t) \mathbf{w}^*}{\|\mathbf{w}(t)\|} \geq \frac{\rho}{R} \sqrt{t}.$$

6. Mostrar que:

$$t \leq \frac{R^2 \|\mathbf{w}^*\|^2}{\rho^2}.$$

Indicação: Lembramos que a *desigualdade de Cauchy-Schwartz* nos diz que o produto escalar de dois vetores é sempre menor do que o produto das normas: $|\mathbf{w}^\top(t) \mathbf{w}^*| \leq \|\mathbf{w}(t)\| \|\mathbf{w}^*\|$.

7. Justificar que a desigualdade do item precedente pode na verdade ser simplificada em:

$$t \leq \frac{1}{\rho^2}.$$

8. Concluir.