

Lista 2

Exercício 1 - Hoeffding

Nesse exercício completamos a demonstração da desigualdade de Hoeffding (a parte da demonstração feita durante a aula está disponível no e-disciplinas).

1. Demonstrar a desigualdade de Markov.
2. Demonstrar o Lemma de Hoeffding.
 - (a) Para um $s > 0$ qualquer, justificar que, para todo $x \in [c, d]$ temos:

$$e^{sx} \leq \frac{d-x}{d-c} e^{sc} + \frac{x-c}{d-c} e^{sd}$$

- (b) Definimos a seguinte função:

$$L(x) = \frac{cx}{d-c} + \ln \left(1 + \frac{c-ce^x}{d-c} \right).$$

Usando o item precedente mostrar que:

$$\mathbb{E} \left[e^{sX} \right] \leq e^{L(s(d-c))}.$$

- (c) Verificar que $L(0) = L'(0) = 0$
 - (d) Justificar que, para um x qualquer, temos $L''(x) \leq 1/4$.
Indicação: Usar a desigualdade das médias.
 - (e) Usar o Teorema de Taylor para concluir.
3. Justificar que, para demonstrar a desigualdade de Hoeffding, basta demonstrar o seguinte:

$$\mathbb{P} [|S_n - \mathbb{E}[S_n]| \geq t] \leq 2 \exp \left(-\frac{2t^2}{n(b-a)^2} \right).$$

4. Calcular o mínimo da função $f(s) = \frac{n(b-a)^2}{8} s^2 - ts$ na semirreta $\mathbb{R}_+^* =]0, +\infty[$.
5. Adaptar os raciocínios apresentados durante a aula para obter a desigualdade:

$$\mathbb{P} [S_n - \mathbb{E}[S_n] \leq -t] \leq \exp \left(-\frac{2t^2}{n(b-a)^2} \right).$$

Exercício 2

Consideramos o **perceptron** em duas dimensões, i.e. $h(x) = \text{sin}(\mathbf{w}^\top \mathbf{x})$ com $\mathbf{w}^\top = (w_0, w_1, w_2)$ e $\mathbf{x}^\top = (1, x_1, x_2)$. Sejam $\mathcal{X}^+$ e $\mathcal{X}^-$ as regiões do plano bidimensional em que h assume os valores $+1$ e -1 respectivamente:

$$\mathcal{X}^+ = \{(x_1, x_2) : h(1, x_1, x_2) = +1\}$$

$$\mathcal{X}^- = \{(x_1, x_2) : h(1, x_1, x_2) = -1\}$$

1. Obtenha a equação da reta que forma a fronteira entre $\mathcal{X}^+$ e $\mathcal{X}^-$ como uma função afim $x_2 = ax_1 + b$, explicitando os valores de a e b em função de w_0, w_1 e w_2 .
2. Se $w_0 = 0$, como essa condição afeta a reta?
3. Descreva o efeito na reta nos seguintes casos:
 - (a) Se multiplicarmos $\mathbf{w}$ por um escalar não nulo $\alpha \neq 0$.
 - (b) Se aumentarmos ou diminuirmos apenas o valor de w_0 .
 - (c) Se aumentarmos ou diminuirmos apenas o valor de w_1 .
 - (d) Se aumentarmos ou diminuirmos apenas o valor de w_2 .

Exercício 3

Considere a seguinte situação: um amigo apresenta a você um problema de aprendizagem, no qual a amostra de treinamento contém 5.000 pontos. No entanto, a função objetivo f é *totalmente desconhecida*, no sentido de que seu amigo não consegue fornecer nenhuma restrição ou informação sobre suas propriedades. Diante desse cenário, qual das três possibilidades a seguir seria a sua resposta?

1. Garanto que, com alta probabilidade, produzirei uma hipótese g , com bom desempenho tanto dentro quanto fora da amostra.
2. Não consigo ajudá-lo. Mesmo que eu conseguisse produzir uma hipótese g que aproxime bem f na amostra de treinamento, não poderia oferecer nenhuma garantia de que ela funcionaria fora dessa amostra.
3. Não posso garantir que funcionará, mas tentarei. Se eu encontrar uma hipótese g com bom desempenho dentro da amostra, então, com alta probabilidade, ela também terá um bom desempenho fora da amostra. Caso contrário, não retornarei nenhuma hipótese.

Exercício 4

Seja $X_1, \dots, X_{10}$ uma sequência de variáveis aleatórias independentes de Bernoulli com parâmetro $p = 0.9$.

1. Calcule $\mathbb{P}[\bar{X} \leq 0.1]$.
2. Obtenha uma cota superior para $\mathbb{P}[\bar{X} \leq 0.1]$ via a **desigualdade de Hoeffding** e comparar com o resultado do item precedente.

Exercício 5

Suponha que você queira aprender uma função $f : \mathcal{X} \rightarrow \mathcal{Y}$, onde $\mathcal{X} = \mathbb{R}$ e $\mathcal{Y} = \{-1, +1\}$. Além disso, suponha que a medida de probabilidade $\mathbb{P}$ em $\mathcal{X}$ satisfaz $\mathbb{P}[f(\mathbf{x}) = +1] = p$. O conjunto de hipóteses é $\mathcal{H} = \{h_+, h_-\}$, onde as hipóteses são funções constantes: $h_+(x) \equiv +1$ e $h_-(x) \equiv -1$. Para um determinado conjunto de treinamento $\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$, o **erro intra-amostal** é definido como:

$$E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n \mathbb{1}_{h(x_k) \neq y_k}.$$

O algoritmo escolhe a hipótese g usando a seguinte regra:

$$g = \begin{cases} h_+ & \text{se } E_{\text{in}}(h_+) \leq E_{\text{in}}(h_-), \\ h_- & \text{caso contrário.} \end{cases}$$

1. É possível garantir que o algoritmo *sempre* produzirá uma hipótese g *melhor que o acaso*?
2. Fixado $\delta \in]0, 1[$, em que situação podemos garantir que o algoritmo produzirá uma hipótese g maior do que o acaso com probabilidade maior que $1 - \delta$?
3. Suponha que $|p - 0.5| > 0.25$. Usando a **desigualdade de Hoeffding**, determine uma cota inferior para n que garanta que g será melhor do que o acaso com probabilidade acima de 99%.

Observação: Embora um algoritmo que produza uma hipótese com a única garantia de ser “melhor do que o acaso” possa parecer um objetivo modesto à primeira vista, existem diversas aplicações nas quais “melhor do que o acaso” é um resultado excelente. Um exemplo é o uso de algoritmos de aprendizagem para investimentos no mercado financeiro.