

# Lista 3

## Exercício 1

Suponha que temos um conjunto de treinamento  $\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$ , onde  $x_k \in \mathbb{R}$  e  $y_k \in \mathbb{R}$  para todo  $1 \leq k \leq n$ . Considere o conjunto de hipóteses  $\mathcal{H}$  definido como  $\mathcal{H} = \cup_{c \in \mathbb{R}} \{h : h(x) \equiv c\}$ , ou seja,  $\mathcal{H}$  é o conjunto de todas as funções reais constantes. O **erro intra-amostrai** é:<sup>1</sup>

$$E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n (h(x_k) - y_k)^2.$$

Calcule  $g = \arg \min_{h \in \mathcal{H}} E_{\text{in}}(h)$ .

## Exercício 2

Suponha novamente que temos um conjunto de treinamento  $\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$ , com  $x_k \in \mathbb{R}$  e  $y_k \in \mathbb{R}$  para todo  $1 \leq k \leq n$ , e o mesmo erro intra-amostrai  $E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n (h(x_k) - y_k)^2$ . Considere agora o conjunto de hipóteses

$$\mathcal{H} = \cup_{a \in \mathbb{R}} \{h : h(x) \equiv ax\},$$

ou seja,  $\mathcal{H}$  é o conjunto das retas que passam pela origem.

- Supondo que  $x_k \neq 0$  para pelo menos um  $k$ , calcule  $g = \arg \min_{h \in \mathcal{H}} E_{\text{in}}(h)$ .
- O que acontece quando  $x_1 = \dots = x_n = 0$ ? Quantos minimizadores existem nesse caso?

## Exercício 3

Suponha que temos um conjunto de treinamento  $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$ , com  $\mathbf{x}_k \in \mathbb{R}^{d+1}$  e  $y_k \in \mathbb{R}$  para todo  $1 \leq k \leq n$ . O conjunto  $\mathcal{D}$  pode ser escrito em formato matricial como:

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{1,0} & \cdots & x_{1,d} \\ \vdots & & \vdots \\ x_{n,0} & \cdots & x_{n,d} \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}.$$

Para  $\mathbf{w} \in \mathbb{R}^{d+1}$ , denotamos o erro dentro do conjunto de treinamento por

$$E_{\text{in}}(\mathbf{w}) \triangleq \sum_{k=1}^n (y_k - \mathbf{w}^\top \mathbf{x}_k)^2 = \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2.$$

Trata-se da soma dos resíduos quadrados associada ao vetor de pesos  $\mathbf{w}$ . Vimos em aula que o gradiente de  $E_{\text{in}}$  se anula nos vetores  $\mathbf{w}$  satisfazendo  $\mathbf{X}^\top \mathbf{X} \mathbf{w} = \mathbf{X}^\top \mathbf{y}$  — esse sistema de equações é frequentemente chamado de *equações normais*. Se  $\mathbf{X}^\top \mathbf{X}$  é invertível, uma solução é então dada por  $\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ . O objetivo deste exercício é justificar que  $\hat{\mathbf{w}}$  é de fato o **mínimo global** de  $E_{\text{in}}$ , e que ele é o **único**, além de estudar as soluções quando  $\mathbf{X}^\top \mathbf{X}$  não é invertível.

- Mostre que sempre temos  $\ker(\mathbf{X}) = \ker(\mathbf{X}^\top \mathbf{X})$ , onde  $\ker(\mathbf{A}) \triangleq \{\mathbf{u} : \mathbf{A}\mathbf{u} = \mathbf{0}\}$ .
- Seja  $\mathbf{w}^*$  uma solução qualquer das equações normais.
  - Mostre que  $\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\mathbf{w}^*) = \mathbf{0}$ , ou seja, que o vetor dos resíduos é ortogonal a todas as colunas de  $\mathbf{X}$ .
  - Escrevendo  $\mathbf{y} - \mathbf{X}\mathbf{w} = (\mathbf{y} - \mathbf{X}\mathbf{w}^*) + \mathbf{X}(\mathbf{w}^* - \mathbf{w})$ , mostre que, para todo  $\mathbf{w} \in \mathbb{R}^{d+1}$  temos:

$$E_{\text{in}}(\mathbf{w}) = E_{\text{in}}(\mathbf{w}^*) + \|\mathbf{X}(\mathbf{w} - \mathbf{w}^*)\|^2.$$

- Deduzza que  $\mathbf{w}^*$  é um mínimo global de  $E_{\text{in}}$ , e que, se  $\mathbf{X}^\top \mathbf{X}$  é invertível, esse mínimo é atingido apenas em  $\mathbf{w}^* = \hat{\mathbf{w}}$ .
- O caso degenerado.** Suponha agora que  $\mathbf{X}^\top \mathbf{X}$  não seja invertível, e seja  $\mathbf{w}^*$  uma solução das equações normais.
    - Mostre que  $\mathbf{w}^* + \mathbf{u}$  também minimiza  $E_{\text{in}}$ , para todo  $\mathbf{u}$  tal que  $\mathbf{X}\mathbf{u} = \mathbf{0}$ , e que há uma infinidade de tais vetores  $\mathbf{u}$ .
    - Mostre, ainda assim, que o vetor de predições  $\hat{\mathbf{y}} = \mathbf{X}\mathbf{w}^*$  é o mesmo para todos os minimizadores.  
**Indicação:** comece justificando que todo minimizador de  $E_{\text{in}}$  é solução das equações normais.
    - Interprete: o que deixa de ser único, e o que permanece único?

<sup>1</sup>Nos Exercícios 1 e 2 o erro intra-amostrai é definido com o fator  $1/n$ ; a partir do Exercício 3 ele será definido sem esse fator. Como se trata de uma constante multiplicativa positiva, isso não altera em nada os minimizadores.

## Exercício 4

Mantemos as notações do exercício precedente. Assumimos que  $\mathbf{X}^\top \mathbf{X}$  é invertível e realizamos uma regressão linear, produzindo o vetor de pesos  $\hat{\mathbf{w}}$  associado. Denotamos por  $\hat{\mathbf{y}}$  o vetor dos **valores preditos**, ou seja, o vetor das predições da regressão linear dentro do conjunto de treinamento:  $\hat{\mathbf{y}} = (\hat{y}_1, \dots, \hat{y}_n)^\top$ , onde  $\hat{y}_k = \hat{\mathbf{w}}^\top \mathbf{x}_k$ .

1. Justifique que  $\hat{\mathbf{y}} = H\mathbf{y}$  para alguma matriz  $H$  e explicita essa matriz (em função de  $\mathbf{X}$ ).

**Observação:**  $H$  é frequentemente chamada de *matriz chapéu* (*hat matrix* em inglês), pois ela “coloca um chapéu” em  $\mathbf{y}$ .

2. Quais são as dimensões da matriz  $H$ ?
3. Para uma matriz  $\mathbf{A}$  qualquer, denotamos por  $\text{span}(\mathbf{A})$  o espaço vetorial gerado pelas colunas de  $\mathbf{A}$ . Mostre que  $\hat{\mathbf{y}}$  é a **projeção ortogonal** de  $\mathbf{y}$  em  $\text{span}(\mathbf{X})$ :
  - (i) Mostre que  $H^2 = H$  (propriedade de projeção).
  - (ii) Mostre que  $H^\top = H$  (propriedade de ortogonalidade).
  - (iii) Justifique que  $\text{span}(H) = \text{span}(\mathbf{X})$ .

4. Poderíamos ter chegado à mesma conclusão sem raciocinar sobre a matriz  $H$ ? Por quê?

**Indicação:** dado um espaço vetorial  $V$  qualquer e um subespaço vetorial  $U \subseteq V$ , a projeção ortogonal de um vetor  $v \in V$  sobre  $U$  é o vetor em  $U$  que está mais próximo de  $v$  em relação à distância euclidiana. Reveja o Exercício 3.

## Exercício 5

No mesmo contexto do exercício precedente, suponha agora que  $\mathbf{X}^\top \mathbf{X}$  não seja invertível. Neste caso, a solução padrão para a regressão linear, vista em aula, não pode ser aplicada diretamente. No entanto, existe uma solução alternativa. Seja  $\rho$  o posto da matriz  $\mathbf{X}$ . Pelo *Teorema da Decomposição em Valores Singulares*, temos que  $\mathbf{X}$  pode ser escrita como  $\mathbf{X} = U\Gamma V^\top$ , onde:

- $U$  é uma matriz  $n \times \rho$  satisfazendo  $U^\top U = I_\rho$ ,
- $V$  é uma matriz  $(d+1) \times \rho$  satisfazendo  $V^\top V = I_\rho$ ,
- $\Gamma$  é uma matriz diagonal  $\rho \times \rho$  com entradas positivas (os  $\rho$  valores singulares não nulos de  $\mathbf{X}$ ).

Mostre que o vetor  $\mathbf{w} = V\Gamma^{-1}U^\top \mathbf{y}$  satisfaz a equação  $\mathbf{X}^\top \mathbf{X}\mathbf{w} = \mathbf{X}^\top \mathbf{y}$  e conclua que  $\mathbf{w}$  minimiza  $E_{\text{in}}$ .

## Exercício 6

Retomamos as notações do Exercício 3. Um pesquisador quer explicar o consumo de energia  $y$  de um prédio a partir da temperatura externa. Distraído, ele inclui a temperatura **duas vezes** no modelo: uma vez em graus Celsius ( $x_{k,1}$ ) e uma vez em graus Fahrenheit ( $x_{k,2} = \frac{9}{5}x_{k,1} + 32$ ). Com  $n = 3$  observações, isso dá:

$$\mathbf{X} = \begin{bmatrix} 1 & 0 & 32 \\ 1 & 10 & 50 \\ 1 & 20 & 68 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 6 \end{bmatrix}.$$

1. Mostre que  $\mathbf{u} = (32, 9/5, -1)^\top \in \ker(\mathbf{X})$ . O que se pode concluir sobre  $\mathbf{X}^\top \mathbf{X}$ ?
2. Verifique que  $\mathbf{w}^* = (1/2, 1/4, 0)^\top$  é uma solução das equações normais.
3. Descreva o conjunto de **todos** os minimizadores de  $E_{\text{in}}$ .
4. Um colega afirma: “o coeficiente da temperatura em Celsius é 1/4, logo cada grau Celsius a mais aumenta o consumo em 0,25 unidade”. Comente.