

Lista 3

Exercício 1

Suponha que temos um conjunto de treinamento $\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$, onde $x_k \in \mathbb{R}$ e $y_k \in \mathbb{R}$ para todo $1 \leq k \leq n$. Considere o conjunto de hipóteses $\mathcal{H}$ definido como $\mathcal{H} = \cup_{c \in \mathbb{R}} \{h : h(x) \equiv c\}$, ou seja, $\mathcal{H}$ é o conjunto de todas as funções reais constantes. O **erro intra-amstral** é:¹

$$E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n (h(x_k) - y_k)^2.$$

Calcule $g = \arg \min_{h \in \mathcal{H}} E_{\text{in}}(h)$.

Exercício 2

Suponha novamente que temos um conjunto de treinamento $\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$, com $x_k \in \mathbb{R}$ e $y_k \in \mathbb{R}$ para todo $1 \leq k \leq n$, e o mesmo erro intra-amstral $E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n (h(x_k) - y_k)^2$. Considere agora o conjunto de hipóteses

$$\mathcal{H} = \cup_{a \in \mathbb{R}} \{h : h(x) \equiv ax\},$$

ou seja, $\mathcal{H}$ é o conjunto das retas que passam pela origem.

1. Supondo que $x_k \neq 0$ para pelo menos um k , calcule $g = \arg \min_{h \in \mathcal{H}} E_{\text{in}}(h)$.
2. O que acontece quando $x_1 = \dots = x_n = 0$? Quantos minimizadores existem nesse caso?

Exercício 3

Suponha que temos um conjunto de treinamento $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$, com $\mathbf{x}_k \in \mathbb{R}^{d+1}$ e $y_k \in \mathbb{R}$ para todo $1 \leq k \leq n$. O conjunto $\mathcal{D}$ pode ser escrito em formato matricial como:

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} = \begin{bmatrix} x_{1,0} & \cdots & x_{1,d} \\ \vdots & & \vdots \\ x_{n,0} & \cdots & x_{n,d} \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}.$$

Para $\mathbf{w} \in \mathbb{R}^{d+1}$, denotamos o erro dentro do conjunto de treinamento por

$$E_{\text{in}}(\mathbf{w}) \triangleq \sum_{k=1}^n (y_k - \mathbf{w}^\top \mathbf{x}_k)^2 = \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2.$$

Trata-se da soma dos resíduos quadrados associada ao vetor de pesos $\mathbf{w}$. Vimos em aula que o gradiente de E_{in} se anula nos vetores $\mathbf{w}$ satisfazendo $\mathbf{X}^\top \mathbf{X} \mathbf{w} = \mathbf{X}^\top \mathbf{y}$ — esse sistema de equações é frequentemente chamado de *equações normais*. Se $\mathbf{X}^\top \mathbf{X}$ é invertível, uma solução é então dada por $\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$. O objetivo deste exercício é justificar que $\hat{\mathbf{w}}$ é de fato o **mínimo global** de E_{in} , e que ele é o **único**, além de estudar as soluções quando $\mathbf{X}^\top \mathbf{X}$ não é invertível.

1. Mostre que sempre temos $\ker(\mathbf{X}) = \ker(\mathbf{X}^\top \mathbf{X})$, onde $\ker(\mathbf{A}) \triangleq \{\mathbf{u} : \mathbf{A}\mathbf{u} = \mathbf{0}\}$.
2. Seja $\mathbf{w}^*$ uma solução qualquer das equações normais.
 - (i) Mostre que $\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\mathbf{w}^*) = \mathbf{0}$, ou seja, que o vetor dos resíduos é ortogonal a todas as colunas de $\mathbf{X}$.
 - (ii) Escrevendo $\mathbf{y} - \mathbf{X}\mathbf{w} = (\mathbf{y} - \mathbf{X}\mathbf{w}^*) + \mathbf{X}(\mathbf{w}^* - \mathbf{w})$, mostre que, para todo $\mathbf{w} \in \mathbb{R}^{d+1}$ temos:

$$E_{\text{in}}(\mathbf{w}) = E_{\text{in}}(\mathbf{w}^*) + \|\mathbf{X}(\mathbf{w} - \mathbf{w}^*)\|^2.$$
 - (iii) Deduza que $\mathbf{w}^*$ é um mínimo global de E_{in} , e que, se $\mathbf{X}^\top \mathbf{X}$ é invertível, esse mínimo é atingido apenas em $\mathbf{w}^* = \hat{\mathbf{w}}$.
3. **O caso degenerado.** Suponha agora que $\mathbf{X}^\top \mathbf{X}$ não seja invertível, e seja $\mathbf{w}^*$ uma solução das equações normais.
 - (i) Mostre que $\mathbf{w}^* + \mathbf{u}$ também minimiza E_{in} , para todo $\mathbf{u}$ tal que $\mathbf{X}\mathbf{u} = \mathbf{0}$, e que há uma infinidade de tais vetores $\mathbf{u}$.
 - (ii) Mostre, ainda assim, que o vetor de predições $\hat{\mathbf{y}} = \mathbf{X}\mathbf{w}^*$ é o mesmo para todos os minimizadores.
Indicação: comece justificando que todo minimizador de E_{in} é solução das equações normais.
 - (iii) Interprete: o que deixa de ser único, e o que permanece único?

¹Nos Exercícios 1 e 2 o erro intra-amstral é definido com o fator $1/n$; a partir do Exercício 3 ele será definido sem esse fator. Como se trata de uma constante multiplicativa positiva, isso não altera em nada os minimizadores.

Exercício 4

Mantemos as notações do exercício precedente. Assumimos que $\mathbf{X}^\top \mathbf{X}$ é invertível e realizamos uma regressão linear, produzindo o vetor de pesos $\hat{\mathbf{w}}$ associado. Denotamos por $\hat{\mathbf{y}}$ o vetor dos **valores preditos**, ou seja, o vetor das predições da regressão linear dentro do conjunto de treinamento: $\hat{\mathbf{y}} = (\hat{y}_1, \dots, \hat{y}_n)^\top$, onde $\hat{y}_k = \hat{\mathbf{w}}^\top \mathbf{x}_k$.

1. Justifique que $\hat{\mathbf{y}} = H\mathbf{y}$ para alguma matriz H e explicita essa matriz (em função de $\mathbf{X}$).

Observação: H é frequentemente chamada de matriz chapéu (*hat matrix* em inglês), pois ela “coloca um chapéu” em $\mathbf{y}$.

2. Quais são as dimensões da matriz H ?
3. Para uma matriz $\mathbf{A}$ qualquer, denotamos por $\text{span}(\mathbf{A})$ o espaço vetorial gerado pelas colunas de $\mathbf{A}$. Mostre que $\hat{\mathbf{y}}$ é a **projeção ortogonal** de $\mathbf{y}$ em $\text{span}(\mathbf{X})$:
 - (i) Mostre que $H^2 = H$ (propriedade de projeção).
 - (ii) Mostre que $H^\top = H$ (propriedade de ortogonalidade).
 - (iii) Justifique que $\text{span}(H) = \text{span}(\mathbf{X})$.

4. Poderíamos ter chegado à mesma conclusão sem raciocinar sobre a matriz H ? Por quê?

Indicação: dado um espaço vetorial V qualquer e um subespaço vetorial $U \subseteq V$, a projeção ortogonal de um vetor $v \in V$ sobre U é o vetor em U que está mais próximo de v em relação à distância euclidiana. Reveja o Exercício 3.

Exercício 5

No mesmo contexto do exercício precedente, suponha agora que $\mathbf{X}^\top \mathbf{X}$ não seja invertível. Neste caso, a solução padrão para a regressão linear, vista em aula, não pode ser aplicada diretamente. No entanto, existe uma solução alternativa. Seja ρ o posto da matriz $\mathbf{X}$. Pelo *Teorema da Decomposição em Valores Singulares*, temos que $\mathbf{X}$ pode ser escrita como $\mathbf{X} = U\Gamma V^\top$, onde:

- U é uma matriz $n \times \rho$ satisfazendo $U^\top U = I_\rho$,
- V é uma matriz $(d+1) \times \rho$ satisfazendo $V^\top V = I_\rho$,
- Γ é uma matriz diagonal $\rho \times \rho$ com entradas positivas (os ρ valores singulares não nulos de $\mathbf{X}$).

Mostre que o vetor $\mathbf{w} = V\Gamma^{-1}U^\top \mathbf{y}$ satisfaz a equação $\mathbf{X}^\top \mathbf{X}\mathbf{w} = \mathbf{X}^\top \mathbf{y}$ e conclua que $\mathbf{w}$ minimiza E_{in} .

Exercício 6

Retomamos as notações do Exercício 3. Um pesquisador quer explicar o consumo de energia y de um prédio a partir da temperatura externa. Distraído, ele inclui a temperatura **duas vezes** no modelo: uma vez em graus Celsius ($x_{k,1}$) e uma vez em graus Fahrenheit ($x_{k,2} = \frac{9}{5}x_{k,1} + 32$). Com $n = 3$ observações, isso dá:

$$\mathbf{X} = \begin{bmatrix} 1 & 0 & 32 \\ 1 & 10 & 50 \\ 1 & 20 & 68 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} 1 \\ 2 \\ 6 \end{bmatrix}.$$

1. Mostre que $\mathbf{u} = (32, 9/5, -1)^\top \in \ker(\mathbf{X})$. O que se pode concluir sobre $\mathbf{X}^\top \mathbf{X}$?
2. Verifique que $\mathbf{w}^* = (1/2, 1/4, 0)^\top$ é uma solução das equações normais.
3. Descreva o conjunto de **todos** os minimizadores de E_{in} .
4. Um colega afirma: “o coeficiente da temperatura em Celsius é 1/4, logo cada grau Celsius a mais aumenta o consumo em 0,25 unidade”. Comente.