

Os Tipos de Aprendizagem

Morgan André

MAE0501 - Aprendizagem Estatística

2º Semestre 2026

Regressão Linear Simples

Exemplo 1: Regressão linear simples

Suponha que você queira estudar a relação entre altura e peso em homens numa determinada população a partir de um conjunto de dados $\mathcal{D} = (x_1, y_1), \dots, (x_n, y_n)$, onde:

Exemplo 1: Regressão linear simples

Suponha que você queira estudar a relação entre altura e peso em homens numa determinada população a partir de um conjunto de dados $\mathcal{D} = (x_1, y_1), \dots, (x_n, y_n)$, onde:

- ▶ x_k é a **altura** do k -ésimo indivíduo.

Exemplo 1: Regressão linear simples

Suponha que você queira estudar a relação entre altura e peso em homens numa determinada população a partir de um conjunto de dados $\mathcal{D} = (x_1, y_1), \dots, (x_n, y_n)$, onde:

- ▶ x_k é a **altura** do k -ésimo indivíduo.
- ▶ y_k é o **peso** do k -ésimo indivíduo.

Exemplo 1: Regressão linear simples

Suponha que você queira estudar a relação entre altura e peso em homens numa determinada população a partir de um conjunto de dados $\mathcal{D} = (x_1, y_1), \dots, (x_n, y_n)$, onde:

- ▶ x_k é a **altura** do k -ésimo indivíduo.
- ▶ y_k é o **peso** do k -ésimo indivíduo.

Realizar uma **regressão linear** consiste em procurar uma relação afim entre os y_k e os x_k .

Exemplo 1: Regressão linear simples

Formalmente, a regressão linear simples assume que $\exists f$ tal que

$$y_i = f(x_i) = \alpha + \beta x_i + \epsilon_i,$$

Exemplo 1: Regressão linear simples

Formalmente, a regressão linear simples assume que $\exists f$ tal que

$$y_i = f(x_i) = \alpha + \beta x_i + \epsilon_i,$$

onde $\epsilon_1, \dots, \epsilon_N \overset{i.i.d.}{\rightsquigarrow} \mathcal{N}(\mu, \sigma^2)$ são termos aleatórios chamados de **erros** ou **resíduos**.

Exemplo 1: Regressão linear simples


Formalmente, a regressão linear simples assume que $\exists f$ tal que

$$y_i = f(x_i) = \alpha + \beta x_i + \epsilon_i,$$


onde $\epsilon_1, \dots, \epsilon_N \overset{i.i.d.}{\rightsquigarrow} \mathcal{N}(\mu, \sigma^2)$ são termos aleatórios chamados de **erros** ou **resíduos**.

Objetivo: achar um $g \in \mathcal{H} = \{\text{conjunto das funções afins}\}$ tal que $g \approx f$. Ou seja: fornecer estimadores $\hat{\alpha}$ e $\hat{\beta}$ para α e β , providenciando o "melhor" ajuste para os pontos da amostra.

Exemplo 1: Regressão linear simples



Exemplo 1: Regressão linear simples



Exemplo 1: Regressão linear simples

- ▶ O que significa achar o "melhor" ajuste?

Exemplo 1: Regressão linear simples

- ▶ O que significa achar o "melhor" ajuste? Significa minimizar a **soma dos quadrados dos resíduos**:

$$(\hat{\alpha}, \hat{\beta}) = \operatorname{argmin}_{\alpha, \beta} \sum_{k=1}^N [y_k - f(x_k)]^2 = \operatorname{argmin}_{\alpha, \beta} \sum_{k=1}^N [y_k - \alpha - \beta x_k]^2$$

Exemplo 1: Regressão linear simples

- ▶ O que significa achar o "melhor" ajuste? Significa minimizar a **soma dos quadrados dos resíduos**:

$$\left(\hat{\alpha}, \hat{\beta}\right) = \operatorname{argmin}_{\alpha, \beta} \sum_{k=1}^N [y_k - f(x_k)]^2 = \operatorname{argmin}_{\alpha, \beta} \sum_{k=1}^N [y_k - \alpha - \beta x_k]^2$$

- ▶ Como o calcular?

Exemplo 1: Regressão linear simples

- ▶ O que significa achar o "melhor" ajuste? Significa minimizar a **soma dos quadrados dos resíduos**:


$$(\hat{\alpha}, \hat{\beta}) = \underset{\alpha, \beta}{\operatorname{argmin}} \sum_{k=1}^N [y_k - f(x_k)]^2 = \underset{\alpha, \beta}{\operatorname{argmin}} \sum_{k=1}^N [y_k - \alpha - \beta x_k]^2$$

- ▶ Como o calcular? Temos a seguinte formula explicita:

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x},$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Exemplo 1: Regressão linear simples



Perceptron

Exemplo 2: Perceptron

Um banco quer automatizar o processo de avaliação dos pedidos de empréstimo

Exemplo 2: Perceptron

Um banco quer automatizar o processo de avaliação dos pedidos de empréstimo, usando o seu **histórico**

Exemplo 2: Perceptron

Um banco quer automatizar o processo de avaliação dos pedidos de empréstimo, usando o seu **histórico** = **info** (*idade, salario* etc.) + **resultado** (*lucro* ou *perda*).

Exemplo 2: Perceptron

Um banco quer automatizar o processo de avaliação dos pedidos de empréstimo, usando o seu **histórico** = **info** (*idade, salario* etc.) + **resultado** (*lucro* ou *perda*).

Formalmente, temos um conjunto $\mathcal{D} = (\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$, onde:

- ▶ $\mathbf{x}_k \in \mathcal{X}$ é um vetor representando as **informações** do k -ésimo cliente.

Exemplo 2: Perceptron

Um banco quer automatizar o processo de avaliação dos pedidos de empréstimo, usando o seu **histórico** = **info** (*idade, salario* etc.) + **resultado** (*lucro* ou *perda*).

Formalmente, temos um conjunto $\mathcal{D} = (\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$, onde:

- ▶ $\mathbf{x}_k \in \mathcal{X}$ é um vetor representando as **informações** do k -ésimo cliente.
- ▶ $y_k \in \mathcal{Y}$ é o **resultado** do empréstimo do k -ésimo indivíduo.

Exemplo 2: Perceptron

Um banco quer automatizar o processo de avaliação dos pedidos de empréstimo, usando o seu **histórico** = **info** (*idade, salario* etc.) + **resultado** (*lucro* ou *perda*).

Formalmente, temos um conjunto $\mathcal{D} = (\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$, onde:

- ▶ $\mathbf{x}_k \in \mathcal{X}$ é um vetor representando as **informações** do k -ésimo cliente.
- ▶ $y_k \in \mathcal{Y}$ é o **resultado** do empréstimo do k -ésimo indivíduo.

No caso $\mathcal{X} = \mathbb{R}^d$ e $\mathcal{Y} = \{-1, +1\}$

Exemplo 2: Perceptron

Um banco quer automatizar o processo de avaliação dos pedidos de empréstimo, usando o seu **histórico** = **info** (*idade, salario* etc.) + **resultado** (*lucro* ou *perda*).

Formalmente, temos um conjunto $\mathcal{D} = (\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$, onde:

- ▶ $\mathbf{x}_k \in \mathcal{X}$ é um vetor representando as **informações** do k -ésimo cliente.
- ▶ $y_k \in \mathcal{Y}$ é o **resultado** do empréstimo do k -ésimo indivíduo.

No caso $\mathcal{X} = \mathbb{R}^d$ e $\mathcal{Y} = \{-1, +1\}$. Assumimos que existe uma função objetiva f modelando a decisão correta (*deferir* ou *indeferir* o empréstimo), num determinado conjunto de possíveis funções $\mathcal{H}$.

Exemplo 2: Perceptron

No modelo do perceptron, as funções $h \in \mathcal{H}$ dependem de dois tipos de parâmetros: os **pesos** $w_1, \dots, w_d \in \mathbb{R}$ e o **limiar** $\theta \in \mathbb{R}$

Exemplo 2: Perceptron

No modelo do perceptron, as funções $h \in \mathcal{H}$ dependem de dois tipos de parâmetros: os **pesos** $w_1, \dots, w_d \in \mathbb{R}$ e o **limiar** $\theta \in \mathbb{R}$. A forma geral de um $h \in \mathcal{H}$ qualquer é dada por:

$$h(\mathbf{x}) = \begin{cases} +1 & \text{se } \sum_{k=1}^d w_k x_k > \theta, \\ -1 & \text{se } \sum_{k=1}^d w_k x_k \leq \theta. \end{cases}$$

Exemplo 2: Perceptron

No modelo do perceptron, as funções $h \in \mathcal{H}$ dependem de dois tipos de parâmetros: os **pesos** $w_1, \dots, w_d \in \mathbb{R}$ e o **limiar** $\theta \in \mathbb{R}$. A forma geral de um $h \in \mathcal{H}$ qualquer é dada por:

$$h(\mathbf{x}) = \begin{cases} +1 & \text{se } \sum_{k=1}^d w_k x_k > \theta, \\ -1 & \text{se } \sum_{k=1}^d w_k x_k \leq \theta. \end{cases}$$

Adicionando uma coordenada artificial $x_0 = 1$ em $\mathbf{x}$, denotando os pesos em formato vetorial $\mathbf{w}^T = (w_0, \dots, w_d)$ com $w_0 = -\theta$, a expressão acima pode ser simplificada:

$$h(\mathbf{x}) = \text{sinal}(\mathbf{w}^T \mathbf{x})$$

Exemplo 2: Perceptron

No modelo do perceptron, as funções $h \in \mathcal{H}$ dependem de dois tipos de parâmetros: os **pesos** $w_1, \dots, w_d \in \mathbb{R}$ e o **limiar** $\theta \in \mathbb{R}$. A forma geral de um $h \in \mathcal{H}$ qualquer é dada por:


$$h(\mathbf{x}) = \begin{cases} +1 & \text{se } \sum_{k=1}^d w_k x_k > \theta, \\ -1 & \text{se } \sum_{k=1}^d w_k x_k \leq \theta. \end{cases}$$

Adicionando uma coordenada artificial $x_0 = 1$ em $\mathbf{x}$, denotando os pesos em formato vetorial $\mathbf{w}^T = (w_0, \dots, w_d)$ com $w_0 = -\theta$, a expressão acima pode ser simplificada:


$$h(\mathbf{x}) = \text{sinal}(\mathbf{w}^T \mathbf{x})$$

Objetivo: O banco procura achar uma função $g \in \mathcal{H}$ tal que $g \approx f$. Trata-se de estimar os pesos $w_0, w_1, \dots, w_d$.


Exemplo 2: Perceptron




restringindo a $x_0 = 1$
→
e descartando x_0




Exemplo 2: Perceptron




Exemplo 2: Perceptron




Exemplo 2: Perceptron




Exemplo 2: Perceptron



Exemplo 2: Perceptron



Exemplo 2: Perceptron



Exemplo 2: Perceptron

Resta a questão principal: como achar o hiperplano separando os dados?

Exemplo 2: Perceptron

Resta a questão principal: como achar o hiperplano separando os dados?

→ **Algoritmo de aprendizagem do perceptron (PLA).**

Exemplo 2: Perceptron

Resta a questão principal: como achar o hiperplano separando os dados?

→ **Algoritmo de aprendizagem do perceptron (PLA).**

1. **Inicialização:** Escolhe um vetor $\mathbf{w} \in \mathbb{R}^{d+1}$ qualquer:

$$\mathbf{w}(0) = \mathbf{w}.$$

Exemplo 2: Perceptron

Resta a questão principal: como achar o hiperplano separando os dados?

→ **Algoritmo de aprendizagem do perceptron (PLA).**

1. **Inicialização:** Escolhe um vetor $\mathbf{w} \in \mathbb{R}^{d+1}$ qualquer:

$$\mathbf{w}(0) = \mathbf{w}.$$

2. **Condição de parada:** Estamos na t -ésima iteração. Se todos os pontos do conjunto $\mathcal{D}$ são corretamente classificados pelo vetor $\mathbf{w}$, pronto! Se não, ir para o item 3.

Exemplo 2: Perceptron

Resta a questão principal: como achar o hiperplano separando os dados?

→ **Algoritmo de aprendizagem do perceptron (PLA).**

1. **Inicialização:** Escolhe um vetor $\mathbf{w} \in \mathbb{R}^{d+1}$ qualquer:

$$\mathbf{w}(0) = \mathbf{w}.$$

2. **Condição de parada:** Estamos na t -ésima iteração. Se todos os pontos do conjunto $\mathcal{D}$ são corretamente classificados pelo vetor $\mathbf{w}$, pronto! Se não, ir para o item 3.
3. **Atualização:** Escolhe um ponto $(\mathbf{x}(t), y(t)) \in \mathcal{D}$ classificado incorretamente e, antes de voltar para o item 2, atualize o vetor dos pesos com a seguinte regra:

$$\mathbf{w}(t+1) = \mathbf{w}(t) + y(t) \mathbf{x}(t).$$

Exemplo 2: Perceptron

Teorema

Se os dados são linearmente separáveis, o PLA sempre funciona.

Exemplo 2: Perceptron

Teorema

Se os dados são linearmente separáveis, o PLA sempre funciona.


Demonstração: Ver lista 1.

Exemplo 2: Perceptron

Teorema

Se os dados são linearmente separáveis, o PLA sempre funciona.

Demonstração: Ver lista 1.



Exemplo 2: Perceptron

Teorema

Se os dados são linearmente separáveis, o PLA sempre funciona.

Demonstração: Ver lista 1.



Exemplo 2: Perceptron

Teorema

Se os dados são linearmente separáveis, o PLA sempre funciona.


Demonstração: Ver lista 1.



Para lidar com dados não linearmente separáveis existem modificações do perceptron, assim como outros modelos mais sofisticados.

A Estrutura dos Problemas de Aprendizagem

Estrutura geral dos problemas de aprendizagem



Os Tipos de Aprendizagem

Tipos de aprendizagem

Pode-se distinguir entre os problemas de regressão, e os problemas de classificação.

Tipos de aprendizagem

Pode-se distinguir entre os problemas de regressão, e os problemas de classificação.

- ▶ **Regressão:** o contra-domínio da função objetiva f é $\mathcal{Y} = \mathbb{R}$.

Tipos de aprendizagem

Pode-se distinguir entre os problemas de regressão, e os problemas de classificação.

- ▶ **Regressão:** o contra-domínio da função objetiva f é $\mathcal{Y} = \mathbb{R}$.
- ▶ **Classificação:** o contra-domínio $\mathcal{Y}$ da função objetiva é finito.

Tipos de aprendizagem

Pode-se distinguir entre os problemas de regressão, e os problemas de classificação.

- ▶ **Regressão:** o contra-domínio da função objetiva f é $\mathcal{Y} = \mathbb{R}$.
- ▶ **Classificação:** o contra-domínio $\mathcal{Y}$ da função objetiva é finito.

Pode ainda se distinguir entre aprendizagem supervisionada, não-supervisionada e por reforço.

Tipos de aprendizagem

Pode-se distinguir entre os problemas de regressão, e os problemas de classificação.

- ▶ **Regressão:** o contra-domínio da função objetiva f é $\mathcal{Y} = \mathbb{R}$.
- ▶ **Classificação:** o contra-domínio $\mathcal{Y}$ da função objetiva é finito.

Pode ainda se distinguir entre aprendizagem supervisionada, não-supervisionada e por reforço.

- ▶ **Supervisionada:** O conjunto de dados contém exemplos explícitos das imagens da função objetiva.

Tipos de aprendizagem

Pode-se distinguir entre os problemas de regressão, e os problemas de classificação.

- ▶ **Regressão:** o contra-domínio da função objetiva f é $\mathcal{Y} = \mathbb{R}$.
- ▶ **Classificação:** o contra-domínio $\mathcal{Y}$ da função objetiva é finito.

Pode ainda se distinguir entre aprendizagem supervisionada, não-supervisionada e por reforço.

- ▶ **Supervisionada:** O conjunto de dados contém exemplos explícitos das imagens da função objetiva.
- ▶ **Por reforço:** O conjunto de dados não contém exemplos explícitos das imagens, mas existe um mecanismo que permite avaliar a qualidade de um valor proposto (Quente ou Frio?).

Tipos de aprendizagem


Pode-se distinguir entre os problemas de regressão, e os problemas de classificação.

- ▶ **Regressão:** o contra-domínio da função objetiva f é $\mathcal{Y} = \mathbb{R}$.
- ▶ **Classificação:** o contra-domínio $\mathcal{Y}$ da função objetiva é finito.


Pode ainda se distinguir entre aprendizagem supervisionada, não-supervisionada e por reforço.

- ▶ **Supervisionada:** O conjunto de dados contém exemplos explícitos das imagens da função objetiva.
- ▶ **Por reforço:** O conjunto de dados não contém exemplos explícitos das imagens, mas existe um mecanismo que permite avaliar a qualidade de um valor proposto (Quente ou Frio?).
- ▶ **Não-supervisionada:** O conjunto de dados não contém nenhuma informação explícita sobre a função objetiva.



Tipos de aprendizagem: classificação (supervisionada)




Tipos de aprendizagem: classificação (supervisionada e/ou não supervisionada).



Tipos de aprendizagem: regressão (supervisionada)



Tipos de aprendizagem: regressão (por reforço)



Medida da qualidade de uma posição:

- ▶ $\approx -1 \rightarrow$ muito ruim.
- ▶ $\approx +1 \rightarrow$ muito boa.