

Modelos Lineares

Morgan André

MAE0501 - Aprendizagem Estatística

2º Semestre 2026

Regressão Linear

Regressão Linear

Já temos evocado a **regressão linear simples**. Trata-se de um modelo de regressão ($\mathcal{Y} = \mathbb{R}$) para dados unidimensionais ($\mathcal{X} = \mathbb{R}$), em que o conjunto de hipóteses é:

$$\mathcal{H} = \bigcup_{\alpha, \beta \in \mathbb{R}} \{h : x \mapsto \alpha + \beta x\}$$

Temos formulas explicitas para estimar o coeficiente angular e o coeficiente linear a partir dos dados de treinamento (ver Exercício 2 na Lista 1):

$$(\hat{\alpha}, \hat{\beta}) = \underset{\alpha, \beta}{\operatorname{argmin}} \sum_{k=1}^n (y_k - \alpha - \beta x_k)^2 \quad \Rightarrow \quad \begin{cases} \hat{\alpha} = \bar{y} - \hat{\beta} \bar{x} \\ \hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{cases}$$

Regressão Linear

$$\mathcal{H} = \bigcup_{\alpha, \beta \in \mathbb{R}} \{h : x \mapsto \alpha + \beta x\}$$

Regressão Linear

$$\mathcal{H} = \bigcup_{\alpha, \beta \in \mathbb{R}} \{h : x \mapsto \alpha + \beta x\}$$

Regressão Linear

$$\mathcal{H} = \bigcup_{w_0, w_1 \in \mathbb{R}} \{h : x \mapsto w_0 + w_1 x\}$$

Regressão Linear

$$\mathcal{H} = \bigcup_{w_0, w_1 \in \mathbb{R}} \{h : x \mapsto w_0 + w_1 x\}$$

Regressão Linear

$$\mathcal{H} = \bigcup_{w_0, w_1 \in \mathbb{R}} \{h : x \mapsto w_0 + w_1 x\}$$

Adicionamos artificialmente uma coordenada a cada elemento do conjunto de dados: $\mathbf{x}_k = (1, x_k) \in \mathbb{R}^2$ para todos os $1 \leq k \leq n$. Assim, podemos denotar $\mathbf{w} = (w_0, w_1)^\top$ e escrever as hipóteses no formato de um produto escalar.

Regressão Linear

$$\mathcal{H} = \bigcup_{w_0, w_1 \in \mathbb{R}} \{h : x \mapsto w_0 + w_1 x\}$$

Adicionamos artificialmente uma coordenada a cada elemento do conjunto de dados: $\mathbf{x}_k = (1, x_k) \in \mathbb{R}^2$ para todos os $1 \leq k \leq n$. Assim, podemos denotar $\mathbf{w} = (w_0, w_1)^\top$ e escrever as hipóteses no formato de um produto escalar.

Regressão Linear

$$\mathcal{H} = \bigcup_{\mathbf{w} \in \mathbb{R}^2} \{h : \mathbf{x} \mapsto \mathbf{w}^T \mathbf{x}\}$$

Adicionamos artificialmente uma coordenada a cada elemento do conjunto de dados: $\mathbf{x}_k = (1, x_k) \in \mathbb{R}^2$ para todos os $1 \leq k \leq n$. Assim, podemos denotar $\mathbf{w} = (w_0, w_1)^T$ e escrever as hipóteses no formato de um produto escalar.

Regressão Linear

$$\mathcal{H} = \bigcup_{\mathbf{w} \in \mathbb{R}^2} \{h : \mathbf{x} \mapsto \mathbf{w}^\top \mathbf{x}\}$$

Adicionamos artificialmente uma coordenada a cada elemento do conjunto de dados: $\mathbf{x}_k = (1, x_k) \in \mathbb{R}^2$ para todos os $1 \leq k \leq n$. Assim, podemos denotar $\mathbf{w} = (w_0, w_1)^\top$ e escrever as hipóteses no formato de um produto escalar.

Regressão Linear

$$\mathcal{H} = \bigcup_{\mathbf{w} \in \mathbb{R}^2} \{h : \mathbf{x} \mapsto \mathbf{w}^T \mathbf{x}\}$$

Adicionamos artificialmente uma coordenada a cada elemento do conjunto de dados: $\mathbf{x}_k = (1, x_k) \in \mathbb{R}^2$ para todos os $1 \leq k \leq n$. Assim, podemos denotar $\mathbf{w} = (w_0, w_1)^T$ e escrever as hipóteses no formato de um produto escalar.

Essa formula se generaliza sem dificuldade ao caso de dados multidimensionais ($\mathbf{x}_k \in \mathbb{R}^d$). O conjunto de hipóteses é:

$$\mathcal{H} = \bigcup_{w_0, w_1, \dots, w_d \in \mathbb{R}} \{h : (x_1, \dots, x_d) \mapsto w_0 + w_1 x_1 + \dots + w_d x_d\}$$

Regressão Linear

$$\mathcal{H} = \bigcup_{\mathbf{w} \in \mathbb{R}^2} \{h : \mathbf{x} \mapsto \mathbf{w}^T \mathbf{x}\}$$

Adicionamos artificialmente uma coordenada a cada elemento do conjunto de dados: $\mathbf{x}_k = (1, x_k) \in \mathbb{R}^2$ para todos os $1 \leq k \leq n$. Assim, podemos denotar $\mathbf{w} = (w_0, w_1)^T$ e escrever as hipóteses no formato de um produto escalar.

Essa formula se generaliza sem dificuldade ao caso de dados multidimensionais ($\mathbf{x}_k \in \mathbb{R}^d$). O conjunto de hipóteses é:

$$\mathcal{H} = \bigcup_{w_0, w_1, \dots, w_d \in \mathbb{R}} \{h : (x_1, \dots, x_d) \mapsto w_0 + w_1 x_1 + \dots + w_d x_d\}$$

Regressão Linear

$$\mathcal{H} = \bigcup_{\mathbf{w} \in \mathbb{R}^2} \{h : \mathbf{x} \mapsto \mathbf{w}^T \mathbf{x}\}$$

Adicionamos artificialmente uma coordenada a cada elemento do conjunto de dados: $\mathbf{x}_k = (1, x_k) \in \mathbb{R}^2$ para todos os $1 \leq k \leq n$. Assim, podemos denotar $\mathbf{w} = (w_0, w_1)^T$ e escrever as hipóteses no formato de um produto escalar.

Essa formula se generaliza sem dificuldade ao caso de dados multidimensionais ($\mathbf{x}_k \in \mathbb{R}^{d+1}$). O conjunto de hipóteses é:

$$\mathcal{H} = \bigcup_{\mathbf{w} \in \mathbb{R}^{d+1}} \{h : \mathbf{x} \mapsto \mathbf{w}^T \mathbf{x}\}$$

Regressão Linear



$$\mathcal{H} = \bigcup_{\mathbf{w} \in \mathbb{R}^2} \{h : \mathbf{x} \mapsto \mathbf{w}^T \mathbf{x}\}$$

Adicionamos artificialmente uma coordenada a cada elemento do conjunto de dados: $\mathbf{x}_k = (1, x_k) \in \mathbb{R}^2$ para todos os $1 \leq k \leq n$. Assim, podemos denotar $\mathbf{w} = (w_0, w_1)^T$ e escrever as hipóteses no formato de um produto escalar.

Essa formula se generaliza sem dificuldade ao caso de dados multidimensionais ($\mathbf{x}_k \in \mathbb{R}^{d+1}$). O conjunto de hipóteses é:

$$\mathcal{H} = \bigcup_{\mathbf{w} \in \mathbb{R}^{d+1}} \{h : \mathbf{x} \mapsto \mathbf{w}^T \mathbf{x}\}$$

Regressão Linear



Regressão Linear

Como para qualquer outro modelo de aprendizagem, o princípio do algoritmo da regressão linear é a **minimização do erro intra-amostal** E_{in}

Regressão Linear

Como para qualquer outro modelo de aprendizagem, o princípio do algoritmo da regressão linear é a **minimização do erro intra-amostal** E_{in} . Neste caso, E_{in} é o **erro quadrático médio**:

$$E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n (h(\mathbf{x}_k) - y_k)^2.$$

Regressão Linear

Como para qualquer outro modelo de aprendizagem, o princípio do algoritmo da regressão linear é a **minimização do erro intra-amostal** E_{in} . Neste caso, E_{in} é o **erro quadrático médio**:

$$E_{\text{in}}(h) = \frac{1}{n} \sum_{k=1}^n (h(\mathbf{x}_k) - y_k)^2.$$

Equivalentemente:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \sum_{k=1}^n (\mathbf{w}^T \mathbf{x}_k - y_k)^2.$$

Regressão Linear

O erro $E_{\text{in}}(\mathbf{w})$ pode ser escrito de forma mais resumida usando a notação matricial:

Regressão Linear

O erro $E_{\text{in}}(\mathbf{w})$ pode ser escrito de forma mais resumida usando a notação matricial:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \sum_{k=1}^n (\mathbf{w}^T \mathbf{x}_k - y_k)^2$$

Regressão Linear

O erro $E_{\text{in}}(\mathbf{w})$ pode ser escrito de forma mais resumida usando a notação matricial:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \sum_{k=1}^n (\mathbf{w}^T \mathbf{x}_k - y_k)^2$$

Regressão Linear

O erro $E_{\text{in}}(\mathbf{w})$ pode ser escrito de forma mais resumida usando a notação matricial:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

Regressão Linear

O erro $E_{\text{in}}(\mathbf{w})$ pode ser escrito de forma mais resumida usando a notação matricial:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

Regressão Linear

O erro $E_{\text{in}}(\mathbf{w})$ pode ser escrito de forma mais resumida usando a notação matricial:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_n^T \end{bmatrix} = \begin{bmatrix} x_{1,0} & \dots & x_{1,d} \\ \vdots & & \vdots \\ x_{n,0} & \dots & x_{n,d} \end{bmatrix} \qquad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$$

Regressão Linear

O nosso objetivo é minimizar o erro intra-amostral:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

Regressão Linear

O nosso objetivo é minimizar o erro intra-amostral:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

Para tal intuito precisamos achar o ponto critico do gradiente:

Regressão Linear

O nosso objetivo é minimizar o erro intra-amostral:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

Para tal intuito precisamos achar o ponto critico do gradiente:

$$\nabla E_{\text{in}}(\mathbf{w})$$

Regressão Linear

O nosso objetivo é minimizar o erro intra-amostral:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

Para tal intuito precisamos achar o ponto critico do gradiente:

$$\nabla E_{\text{in}}(\mathbf{w}) = \begin{bmatrix} \frac{\partial E_{\text{in}}(\mathbf{w})}{\partial w_0} \\ \frac{\partial E_{\text{in}}(\mathbf{w})}{\partial w_1} \\ \vdots \\ \frac{\partial E_{\text{in}}(\mathbf{w})}{\partial w_d} \end{bmatrix}$$

Regressão Linear

O nosso objetivo é minimizar o erro intra-amostral:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

Para tal intuito precisamos achar o ponto critico do gradiente:

$$\nabla E_{\text{in}}(\mathbf{w}) = \begin{bmatrix} \frac{\partial E_{\text{in}}(\mathbf{w})}{\partial w_0} \\ \frac{\partial E_{\text{in}}(\mathbf{w})}{\partial w_1} \\ \vdots \\ \frac{\partial E_{\text{in}}(\mathbf{w})}{\partial w_d} \end{bmatrix} = \frac{2}{n} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y})$$

Regressão Linear

O nosso objetivo é minimizar o erro intra-amostral:

$$E_{\text{in}}(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

Para tal intuito precisamos achar o ponto critico do gradiente:

$$\nabla E_{\text{in}}(\mathbf{w}) = \begin{bmatrix} \frac{\partial E_{\text{in}}(\mathbf{w})}{\partial w_0} \\ \frac{\partial E_{\text{in}}(\mathbf{w})}{\partial w_1} \\ \vdots \\ \frac{\partial E_{\text{in}}(\mathbf{w})}{\partial w_d} \end{bmatrix} = \frac{2}{n} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = \mathbf{0}$$

Regressão Linear

$$\nabla E_{\text{in}}(\mathbf{w}) = \frac{2}{n} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = \mathbf{0}$$

Regressão Linear

$$\nabla E_{\text{in}}(\mathbf{w}) = \frac{2}{n} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = \mathbf{0}$$

Logo, o vetor $\mathbf{w}$ que minimiza $E_{\text{in}}(\mathbf{w})$ satisfaz $\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y}$, e portanto:

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Regressão Linear

$$\nabla E_{\text{in}}(\mathbf{w}) = \frac{2}{n} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = \mathbf{0}$$

Logo, o vetor $\mathbf{w}$ que minimiza $E_{\text{in}}(\mathbf{w})$ satisfaz $\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y}$, e portanto:

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

A matriz $\mathbf{X}^\dagger = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ é chamada de **matriz pseudoinversa**.

Regressão Linear

$$\nabla E_{\text{in}}(\mathbf{w}) = \frac{2}{n} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = \mathbf{0}$$

Logo, o vetor $\mathbf{w}$ que minimiza $E_{\text{in}}(\mathbf{w})$ satisfaz $\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y}$, e portanto:

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

A matriz $\mathbf{X}^\dagger = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ é chamada de **matriz pseudoinversa**.

Observação: Para que $\mathbf{X}^\dagger$ seja corretamente definida é preciso que $\mathbf{X}^T \mathbf{X}$ seja invertível. Isso não é um problema na pratica pois uma matriz $\mathbf{X}$ tem colunas linearmente independentes se e somente se $\mathbf{X}^T \mathbf{X}$ é invertível. Como $n \gg d$ no nosso caso, é extremamente improvável que as colunas sejam linearmente dependentes.

Regressão Linear

O "algoritmo" da regressão linear é portanto bastante simples:

Regressão Linear

O "algoritmo" da regressão linear é portanto bastante simples:

1. Dispor os dados no formato matricial.

Regressão Linear

O "algoritmo" da regressão linear é portanto bastante simples:

1. Dispor os dados no formato matricial.
2. Calcular o inverso de $\mathbf{X}^T \mathbf{X}$ para obter a matriz pseudoinversa

$$\mathbf{X}^\dagger = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$

Regressão Linear

O "algoritmo" da regressão linear é portanto bastante simples:

1. Dispor os dados no formato matricial.
2. Calcular o inverso de $\mathbf{X}^T \mathbf{X}$ para obter a matriz pseudoinversa

$$\mathbf{X}^\dagger = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$

3. Aplicar a formula

$$\mathbf{w} = \mathbf{X}^\dagger \mathbf{y}$$

Regressão Linear

O "algoritmo" da regressão linear é portanto bastante simples:

1. Dispor os dados no formato matricial.
2. Calcular o inverso de $\mathbf{X}^T \mathbf{X}$ para obter a matriz pseudoinversa

$$\mathbf{X}^\dagger = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$

3. Aplicar a formula

$$\mathbf{w} = \mathbf{X}^\dagger \mathbf{y}$$

Observação: $\mathbf{X}^T \mathbf{X}$ é uma matriz $(d + 1) \times (d + 1)$, em particular as suas dimensões não dependem de n . Portanto, computacionalmente, a inversão dessa matriz não representa um problema.

Perceptron VS Regressão Linear

Perceptron VS Regressão Linear

Agora percebemos que o Perceptron e a Regressão Linear são modelos bastante similares.

Perceptron VS Regressão Linear

Agora percebemos que o Perceptron e a Regressão Linear são modelos bastante similares.

Perceptron

$$h(\mathbf{x}) = \text{sig}(\mathbf{w}^T \mathbf{x})$$

Regressão Linear

$$h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$$

Perceptron VS Regressão Linear

Agora percebemos que o Perceptron e a Regressão Linear são modelos bastante similares.

Perceptron

$$h(\mathbf{x}) = \text{sinal}(\mathbf{w}^T \mathbf{x})$$

Regressão Linear

$$h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$$

Na verdade, esses dois modelos pertencem a uma mesma classe: os **Modelos Lineares**. A classe dos modelos lineares não se reduz a esses dois, são todos os modelos em que as hipóteses podem ser escritas:

$$h(\mathbf{x}) = \phi(\mathbf{w}^T \mathbf{x})$$

Perceptron VS Regressão Linear

Agora percebemos que o Perceptron e a Regressão Linear são modelos bastante similares.

Perceptron

$$h(\mathbf{x}) = \text{sinal}(\mathbf{w}^T \mathbf{x})$$

Regressão Linear

$$h(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$$

Na verdade, esses dois modelos pertencem a uma mesma classe: os **Modelos Lineares**. A classe dos modelos lineares não se reduz a esses dois, são todos os modelos em que as hipóteses podem ser escritas:

$$h(\mathbf{x}) = \phi(\mathbf{w}^T \mathbf{x})$$

No caso do perceptron $\phi(x) = \text{sinal}(x)$ e no caso da regressão linear temos simplesmente $\phi(x) = x$.

Perceptron VS Regressão Linear

Os dois modelos apresentam tanta similaridade que a regressão linear pode ser usada para resolver problemas de classificação.

Perceptron VS Regressão Linear

Os dois modelos apresentam tanta similaridade que a regressão linear pode ser usada para resolver problemas de classificação. De fato, $+1$ e -1 são, entre outras coisas, números reais!

Perceptron VS Regressão Linear

Os dois modelos apresentam tanta similaridade que a regressão linear pode ser usada para resolver problemas de classificação. De fato, $+1$ e -1 são, entre outras coisas, números reais!

Sendo assim, é possível proceder da seguinte forma.

Perceptron VS Regressão Linear

Os dois modelos apresentam tanta similaridade que a regressão linear pode ser usada para resolver problemas de classificação. De fato, $+1$ e -1 são, entre outras coisas, números reais!

Sendo assim, é possível proceder da seguinte forma. Obter $\mathbf{w}$ via o algoritmo da regressão linear (bem menos custoso do que o PLA).

Perceptron VS Regressão Linear

Os dois modelos apresentam tanta similaridade que a regressão linear pode ser usada para resolver problemas de classificação. De fato, $+1$ e -1 são, entre outras coisas, números reais!

Sendo assim, é possível proceder da seguinte forma. Obter $\mathbf{w}$ via o algoritmo da regressão linear (bem menos custoso do que o PLA). Dessa forma deveríamos ter:

$$\mathbf{w}^T \mathbf{x}_k \approx y_k \quad \text{para todo } 1 \leq k \leq n.$$

Perceptron VS Regressão Linear

Os dois modelos apresentam tanta similaridade que a regressão linear pode ser usada para resolver problemas de classificação. De fato, $+1$ e -1 são, entre outras coisas, números reais!

Sendo assim, é possível proceder da seguinte forma. Obter $\mathbf{w}$ via o algoritmo da regressão linear (bem menos custoso do que o PLA). Dessa forma deveríamos ter:

$$\mathbf{w}^T \mathbf{x}_k \approx y_k \quad \text{para todo } 1 \leq k \leq n.$$

- ▶ Em particular, se $y_k = +1$, então espera-se que $\mathbf{w}^T \mathbf{x}_k > 0$.
- ▶ Ao contrario, se $y_k = -1$, então espera-se que $\mathbf{w}^T \mathbf{x}_k < 0$.

Perceptron VS Regressão Linear

Os dois modelos apresentam tanta similaridade que a regressão linear pode ser usada para resolver problemas de classificação. De fato, $+1$ e -1 são, entre outras coisas, números reais!

Sendo assim, é possível proceder da seguinte forma. Obter $\mathbf{w}$ via o algoritmo da regressão linear (bem menos custoso do que o PLA). Dessa forma deveríamos ter:

$$\mathbf{w}^T \mathbf{x}_k \approx y_k \quad \text{para todo } 1 \leq k \leq n.$$

- ▶ Em particular, se $y_k = +1$, então espera-se que $\mathbf{w}^T \mathbf{x}_k > 0$.
- ▶ Ao contrario, se $y_k = -1$, então espera-se que $\mathbf{w}^T \mathbf{x}_k < 0$.

Portanto, com esse $\mathbf{w}$, é provável que $\text{ sinal}(\mathbf{w}^T \mathbf{x}_k) = y_k$.

Perceptron VS Regressão Linear

Embora a regressão linear possa ser usada para resolver problemas de classificação, ela não é realmente adequada para tal tarefa, pois ela irá penalizar inutilmente previsões muito acima de $+1$, ou muito abaixo de -1 .

Perceptron VS Regressão Linear

Embora a regressão linear possa ser usada para resolver problemas de classificação, ela não é realmente adequada para tal tarefa, pois ela irá penalizar inutilmente previsões muito acima de $+1$, ou muito abaixo de -1 .

No entanto, o $\mathbf{w}$ obtido graças a regressão linear:

1. tem boas chance de apresentar um desempenho muito acima de uma escolha arbitrária,
2. apresenta um baixo custo computacional.

Perceptron VS Regressão Linear

Embora a regressão linear possa ser usada para resolver problemas de classificação, ela não é realmente adequada para tal tarefa, pois ela irá penalizar inutilmente previsões muito acima de $+1$, ou muito abaixo de -1 .

No entanto, o $\mathbf{w}$ obtido graças a regressão linear:

1. tem boas chance de apresentar um desempenho muito acima de uma escolha arbitrária,
2. apresenta um baixo custo computacional.

Essas duas observações sugerem a seguinte estratégia:


1. obter primeiro um $\mathbf{w}'$ via regressão linear,
2. na seguida usar o PLA com a inicialização $\mathbf{w}(0) = \mathbf{w}'$.

Modelos Lineares & Dados Lineares

Operadores Booleanos

		Linearmente separáveis		Não linearmente separável
A	B	A AND B	A OR B	A XOR B
0	0	0	0	0
0	1	0	1	1
1	0	0	1	1
1	1	1	1	0

MNIST Data Set




Classificação de Algoritmos

Cada imagem = $16 \times 16 = 256$ pixels. Logo o nível de **complexidade** de $\mathcal{H}$ no dados brutos é extremamente alto.


Portanto reduzimos a dimensionalidade dos dados, resumindo cada imagem num vetor $\mathbf{x} = (x_0, x_1, x_2)$, onde:

- ▶ $x_1 =$ **intensidade total**
- ▶ $x_2 =$ **simetria**


Agora, o vetor que estamos procurando é da forma $\mathbf{w} = (w_0, w_1, w_2)$. Com apenas 3 coordenadas, a complexidade de $\mathcal{H}$ foi drasticamente reduzida.



Classificação de Algarismos




Classificação de Algoritmos





Os dados não são linearmente separáveis, portanto o **PLA** deve ser interrompido manualmente após um certo número T de iterações.

Classificação de Algoritmos



Algoritmo Pocket: modificação bastante simples do **PLA**, em que retornamos o melhor $\mathbf{w}$ obtido durante as T primeiras iterações.

Classificação de Algoritmos



Algoritmo Pocket: modificação bastante simples do **PLA**, em que retornamos o melhor $\mathbf{w}$ obtido durante as T primeiras iterações.

Transformação Não Linear

$$\psi(x_1, x_2) = (x_1^2, x_2^2)$$

